Результаты перехода к реальным данным

Текущий статус

На этом шаге реализованы и реально посчитаны первые части плана из plan.md:

1. `A0` — подготовка корпусов данных;
2. `A1` — первичный выбор основного наблюдаемого ряда для `IPP`;
3. `A2/A3` — перенос маршрутизатора на реальные окна и фильтр интерпретируемости.

Пока основным эмпирическим корпусом выступают месячные индексы промышленного производства. Линия выручки уже подготовлена в tidy-формате, но содержательные эксперименты по ней ещё не начаты.

A0. Подготовка корпусов

Полученные файлы

- ipp_long.csv
- ipp_hierarchy.csv
- revenue_wide.csv
- revenue_long.csv

Сводка по корпусам

Корпус	Наблюдения	Комментарий
`IPP long`	21,996	47 серий × 3 варианта × 156 месяцев
`IPP hierarchy`	47	Иерархия рядов для отраслевых сопоставлений
`Revenue wide`	23,943	Стабильные компании, 2003–2022
`Revenue long`	478,860	23,943 компании × 20 лет

Ключевые технические выводы

1. Промышленный файл успешно раскрыт как корпус из 47 рядов, каждый в трёх версиях: `adj_smoothed`, `adj_unsmoothed`, `raw`.
2. Горизонт `IPP` подтверждён: `2013-01` — `2025-12`.
3. По выручке подтверждена большая доля пропусков по ОКВЭД: около `22.2%`.
4. Это ещё раз поддерживает решение начинать эмпирический анализ именно с промышленного массива.

A1. Выбор основного наблюдаемого ряда для `IPP`

Постановка

На первом шаге сравнивались три наблюдения одного и того же отраслевого процесса:

- `adj_smoothed`
- `adj_unsmoothed`
- `raw`

Базовая конфигурация окна:

- `W = 24`
- `L = 3`

Результаты baseline-расчёта сохранены в:

- variant_summary.csv
- series_summary.csv

Интегральная сводка по вариантам ряда

Вариант	Серий	mean Var(omega)	mean ACF1	mean ACF2	no-model share	mean cond	mean R2
`adj_smoothed`	47	0.000579	0.986223	0.951738	0.000000	69.862329	0.948516
`adj_unsmoothed`	47	0.006601	0.887660	0.856962	0.000000	3.452471	0.405905
`raw`	47	0.023603	0.730063	0.618777	0.000000	3.389284	0.502995

Промежуточная интерпретация

1. `adj_smoothed` даёт почти идеальную автокорреляцию и очень высокий `R2`, но платой за это становится сильное “размазывание” динамики и завышенная инерционность.
2. `raw` существенно повышает дисперсию темпа роста и разрушает автокорреляционную структуру, то есть вносит слишком много календарного и нерегулярного шума.
3. `adj_unsmoothed` занимает промежуточное положение и на этом этапе выглядит лучшим кандидатом на основной слой для структурного чтения.

Рабочий вывод по `A1`

На текущем этапе в качестве **основного рабочего слоя** для дальнейшего анализа принимается `adj_unsmoothed`.

Смысл выбора:

- `adj_smoothed` использовать как вспомогательный слой для визуализации и very local probe;

- `adj_unsmoothed` использовать как основной слой для routing и структурного чтения;
- `raw` использовать как stress-test на устойчивость результата.

Expanded sensitivity: `W = 24, 36, 48` **и** `L = 3, 6`

Результаты расширенного прогона сохранены в:

- variant_summary.csv

Главные наблюдения по расширенной сетке:

1. При всех окнах и обоих лаговых пространствах `adj_smoothed` остаётся самым инерционным и самым "слишком хорошим" вариантом: у него максимальные `ACF1/ACF2`, высокий `R2`, но и резко возрастающая обусловленность при `L = 6`.
2. `raw` стабильно даёт наибольшую `Var(omega)` и сохраняет шумовой характер даже при длинных окнах.
3. `adj_unsmoothed` сохраняет статус лучшего компромисса и в expanded-сетке.

Особенно важно:

- для `adj_unsmoothed` рост окна с `24` до `48` уменьшает `mean R2` при `L = 3` (`0.406 -> 0.278`), то есть длинное окно не даёт "чуда fit";
- при `L = 6` `adj_unsmoothed` становится несколько плотнее (`mean R2` выше), но всё ещё не уходит в искусственную инерционность `adj_smoothed`;
- у `adj_smoothed` при `L = 6` `mean_cond` становится экстремально большим: от `620.6` до `923.9`.

Это усиливает исходный вывод: **`adj_smoothed` не должен быть основным структурным слоем**.

A2/A3. Перенос маршрутизатора и фильтр интерпретируемости

Артефакты

- window_features.csv
- regime_summary.csv
- interpretability_summary.csv
- routing_summary.csv

Использовалась та же базовая конфигурация:

- `W = 24`
- `L = 3`

Всего в baseline было обработано `18,753` окон по `47` сериям и `3` вариантам наблюдения.

Распределение режимов по вариантам ряда

Вариант	growth no memory	memory-like growth	plateau	turbulent informative
`adj_smoothed`	0.068629	0.348744	0.578787	0.003839
`adj_unsmoothed`	0.002240	0.004799	0.172772	0.820189
`raw`	0.007359	0.155815	0.000960	0.835866

Распределение классов интерпретируемости

Вариант	interpretable	collinearity heavy	low dispersion	plateau
`adj_smoothed`	0.353863	0.055831	0.011518	0.578787
`adj_unsmoothed`	0.649016	0.104303	0.073908	0.172772
`raw`	0.779235	0.115182	0.104623	0.000960

Что здесь важно

1. `adj_smoothed` действительно слишком часто уходит в `plateau_degenerate`. Это сильный аргумент против использования сглаженного ряда как основного слоя структурной интерпретации.
2. `raw` даёт наибольшую долю формально `interpretable` окон, но почти целиком маршрутизируется в `turbulent_informative`. Это не преимущество, а указание на то, что шум делает динамику слишком турбулентной для спокойного регрессионного чтения.
3. `adj_unsmoothed` выглядит наиболее сбалансированным вариантом. Он ещё сохраняет высокий уровень интерпретируемости (`~64.9%` окон), но не проваливается в тотальную plateau-деградацию, как `adj_smoothed`.

Практическое routing-следствие

Для `adj_unsmoothed` распределение preferred tool получилось таким:

Инструмент	Доля окон
`phase_short_forecast`	0.746761
`do_not_read_regression`	0.246681
`structural_regression`	0.004319
`direct_probe + enter`	0.002240

Это очень жёсткий, но содержательный результат: на реальных окнах короткая структурная регрессия допустима далеко не всегда. Уже сейчас видно, что

реальная промышленная динамика чаще отправляет окно либо в осторожный фазовый контур, либо вообще в режим “не читать обычную регрессию”.

Expanded sensitivity для `adj_unsmoothed`: `W = 24, 36, 48`, `L = 6`

Расширенный прогон сохранён в:

- interpretability_summary.csv
- regime_summary.csv

Ключевой результат здесь очень сильный:

Окно	interpretable	collinearity heavy	low dispersion	plateau
24	0.643257	0.110062	0.073908	0.172772
36	0.686302	0.113417	0.086513	0.113768
48	0.724185	0.104626	0.083740	0.087449

То есть при увеличении окна:

1. доля `interpretable` окон растёт;
2. доля `plateau_degenerate` заметно падает;
3. `collinearity_heavy` остаётся почти на том же уровне.

Это уже почти прямое подтверждение твоей синтетической логики:

> увеличение окна действительно помогает против исчезающего сигнала, но не устраняет проблему содержательной коллинеарности.

По режимам картина тоже устойчива:

Окно	turbulent informative	plateau
24	0.820189	0.172772
36	0.881836	0.113768
48	0.911185	0.087449

Это значит, что длинное окно не делает реальные ряды “простыми”; оно лишь уменьшает долю деградировавших окон и переводит больше случаев в турбулентный, но ещё информативный режим.

Первые отраслевые наблюдения для `adj_unsmoothed`

Серии с наибольшей долей интерпретируемых окон

Код	Серия	interpretable share	dominant regime
21	Производство лекарственных средств	0.842105	turbulent informative
39	Предоставление услуг в области ликвидации загрязнений	0.827068	turbulent informative
18	Деятельность полиграфическая	0.827068	turbulent informative
31	Производство мебели	0.819549	turbulent informative
16	Обработка древесины	0.819549	turbulent informative
06.2	Добыча природного газа и газового конденсата	0.804511	turbulent informative

Серии с наиболее выраженной plateau-деградацией

Код	Серия	plateau share	dominant regime
07	Добыча металлических руд	0.857143	plateau degenerate
36	Забор, очистка и распределение воды	0.857143	plateau degenerate
ПРОМ	Промышленность - всего	0.849624	plateau degenerate
B	Добыча полезных ископаемых	0.759398	plateau degenerate
06	Добыча сырой нефти и природного газа	0.751880	plateau degenerate
06.1	Добыча сырой нефти	0.751880	plateau degenerate

Комментарий

Это хорошо согласуется с экономическим смыслом:

- многие высокоагрегированные ряды действительно выглядят “инерционными” и часто уходят в plateau-тип окна;
- более узкие и волатильные отрасли чаще оказываются информативными, но уже не в простом growth-режиме, а в турбулентном.

Графики

Карта режимов по вариантам

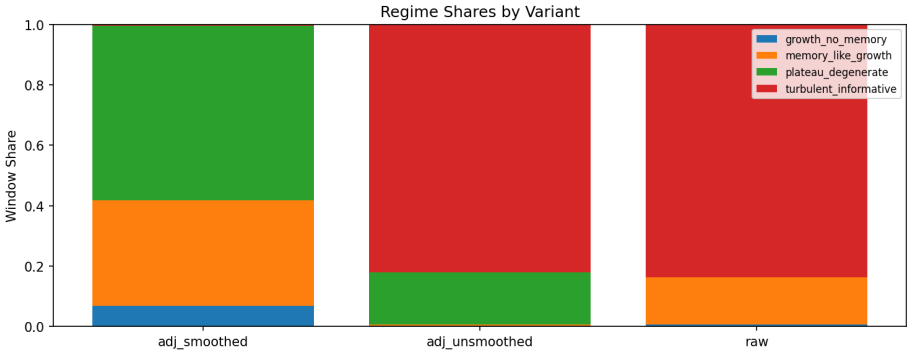

Figure 1: Regime Shares

Карта интерпретируемости по вариантам

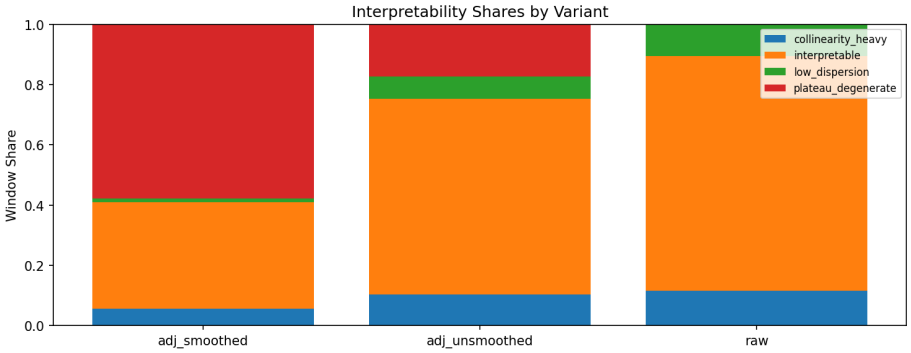

Figure 2: Interpretability Shares

Scatter `Var(omega)` vs `cond(X_scaled)`

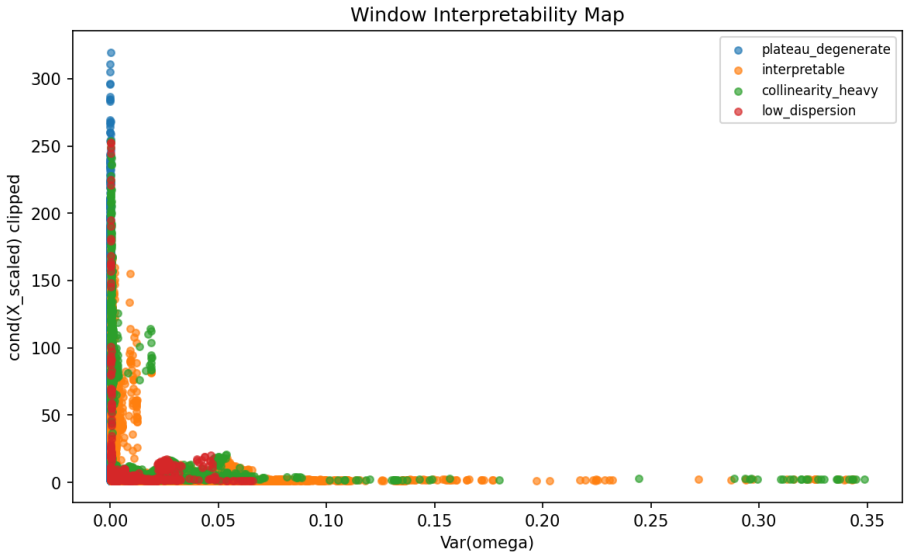

Figure 3: Var Cond Scatter

Текущий промежуточный вывод

На данный момент уже можно зафиксировать три результата.

1. Переход к реальным данным технически состоялся: оба корпуса приведены к рабочему long-format.
2. Для промышленного корпуса baseline-расчёты поддерживают выбор `adj_unsmoothed` как основного наблюдаемого ряда.
3. Реальные короткие окна действительно требуют того самого маршрута, который был выведен на синтетике: сначала режим, затем интерпретируемость, затем выбор контура, и только потом чтение структуры.

Самый важный ранний вывод здесь такой: **на живых рядах короткая регрессия не является default-операцией**. Значительная часть окон либо уходит в plateau/low-dispersion, либо требует осторожного фазового чтения вместо прямой интерпретации списка лагов.

A4. Структурное чтение окон для `adj_unsmoothed`

Артефакты

- window_structures.csv
- series_summary.csv
- mode_summary.csv
- mode_shares.png

- top_interpretable_series.png

На этом шаге структурное чтение строилось только для основного рабочего слоя `adj_unsmoothed` и только в baseline-конфигурации:

- `W = 24`
- `L = 3`

Распределение режимов структурного чтения

Режим чтения	Доля окон
`phase_caution`	0.644697
`do_not_read`	0.246681
`beta_bsum_caution`	0.102064
`memory_structure`	0.004319
`current_state`	0.002240

Интерпретация

Это подтверждает предыдущий routing-результат в более содержательной форме.

1. Основная масса реальных окон не допускает прямого “чтения лагов как структуры памяти”.
2. Наиболее частый рабочий режим — `phase_caution`, то есть сначала фазовый и качественный анализ, а не буквальная регрессионная интерпретация.
3. Чисто memory-like окна на реальных `IPP`-рядах редки.
4. Окна, в которых допустимо осторожное чтение через `beta + B_sum`, есть, но это меньшинство.

Поведение доминирующего фактора

В `adj_unsmoothed`-окнах лидером по `|beta|` чаще всего остаётся `X_n`:

reading mode	top beta predictor	окон
`phase_caution`	`X_n`	3262
`do_not_read`	`X_n`	1190
`beta_bsum_caution`	`X_n`	374
`phase_caution`	`Lag_1`	321
`phase_caution`	`Lag_2`	265
`phase_caution`	`Lag_3`	182

Промежуточный смысл этого результата такой:

- даже в турбулентных окнах текущий уровень ряда чаще остаётся главным фактором локальной динамики;
- память в реальных `IPP`-рядах присутствует, но редко доминирует так же чисто, как в synthetic delay/mixed-кейсах.

Поведение `B_sum`

Распределение суммарного лагового эффекта по baseline-окнам:

Метрика	Значение
mean	0.000820
std	0.004188
min	-0.028559
25%	-0.001537
median	0.000784
75%	0.003182
max	0.039744

На этом этапе это указывает на важную вещь: в среднем суммарный лаговый эффект по реальным окнам невелик и концентрируется близко к нулю. Значит, на реальных промышленных рядах гораздо важнее отличать:

- сильный сигнал текущего состояния;
- слабую/вторичную память;
- и ложную структурную активность, возникающую на турбулентных окнах.

Серии с наибольшей долей допускаемых интерпретируемых чтений

По итогам `series_summary.csv` наиболее “читаемыми” сериями оказались:

Код	Серия	interpretable share	dominant mode	dominant top beta
`21`	Производство лекарственных средств	0.842105	`phase_caution`	`X_n`
`18`	Деятельность полиграфическая	0.827068	`phase_caution`	`X_n`
`39`	Услуги по ликвидации загрязнений	0.827068	`phase_caution`	`X_n`
`16`	Обработка древесины	0.819549	`phase_caution`	`X_n`
`31`	Производство мебели	0.819549	`phase_caution`	`X_n`

Код	Серия	interpretable share	dominant mode	dominant top beta
15	Производство кожи	0.812030	phase_cautionX_n	

Это тоже характерно: даже у наиболее интерпретируемых серий доминирующий режим чтения остаётся осторожным, а не “чистой структурной регрессией”.

Графики

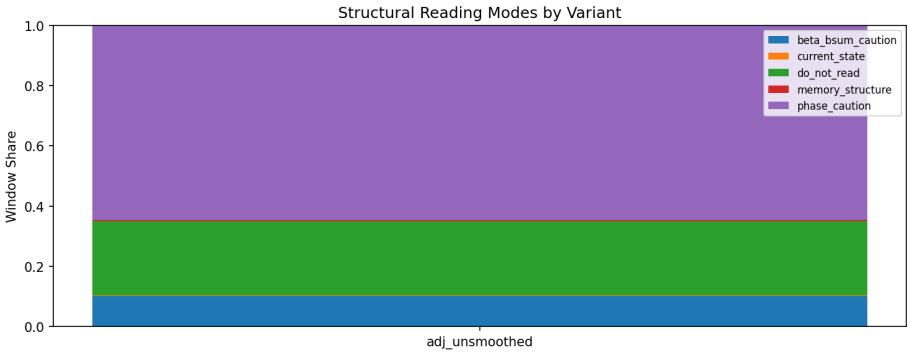

Figure 4: Mode Shares

Карта режимов структурного чтения

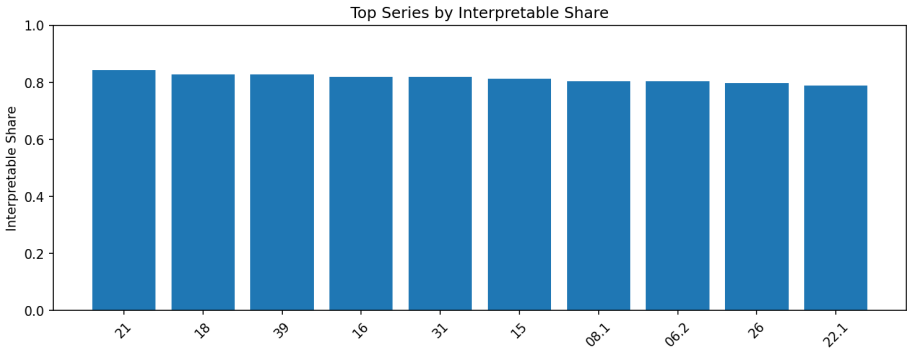

Figure 5: Top Interpretable Series

Серии с наибольшей долей интерпретируемых окон

Вывод по A4

Промежуточный методологический вывод после A4 такой:

> даже на выбранном основном рабочем слое adj_unsmoothed короткое окно чаще требует осторожного качественно-структурного чтения, чем прямой параметрической интерпретации.

Именно это и делает связку из A2, A3 и A4 полезной:

- A2 отвечает за режим;
- A3 — за допуск к интерпретации;
- A4 — за форму допустимого чтения окна.

Expanded sensitivity для A4: W = 24, 36, 48, L = 6

Расширенные артефакты:

- mode_summary.csv
- series_summary.csv
- mode_shares.png
- top_interpretable_series.png

Интегральная картина по expanded-прогону:

reading mode	window share
phase_caution	0.678975
do_not_read	0.208546
beta_bsum_caution	0.108376
memory_structure	0.002462
current_state	0.001641

По сравнению с baseline это означает:

1. доля phase_caution ещё увеличивается;
2. доля do_not_read уменьшается;
3. чисто memory-like окна остаются редкими даже при более длинных окнах и L = 6.

Иначе говоря, увеличение окна помогает извлечь больше **допустимых** окон, но не переводит реальный промышленный ряд в простую memory-regression картину.

Expanded-top серии тоже немного сдвигаются. В expanded-сетке наиболее читаемыми оказываются:

Код	Серия	interpretable share	dominant mode
13	Производство текстильных изделий	0.818182	phase_caution
16	Обработка древесины	0.818182	phase_caution
39	Услуги по ликвидации загрязнений	0.818182	phase_caution
30.2	Производство железнодорожных средств	0.815427	phase_caution
31	Производство мебели	0.812672	phase_caution

То есть состав “лучших” отраслей остаётся похожим, а dominant mode не меняется: это всё ещё осторожное фазово-структурное чтение, а не прямое чтение памяти.

A5. Baseline consistency для `adj_unsmoothed`

Артефакты

- overall_summary.csv
- series_consistency.csv
- variant_consistency.csv
- variant_consistency.png

Пока consistency-слой рассчитан для baseline-конфигурации:

- `variant = adj_unsmoothed`
- `W = 24`
- `L = 3`

То есть это ещё не полный `A5` по всем окнам и вариантам, а первая опорная версия.

Интегральная сводка

Метрика	Среднее значение
regime consistency	0.907695
interpretability consistency	0.740522
tool consistency	0.834267
top beta consistency	0.772516

Метрика	Среднее значение
top B consistency	0.762918
reading mode consistency	0.737002

Что это означает

1. На уровне baseline-анализа режим окна оказывается довольно устойчивым.
2. Интерпретируемость и режим чтения уже менее стабильны, но всё ещё остаются заметно выше случайного уровня.
3. Доминирующий фактор по `|beta|` и по `|B|` в среднем совпадает не идеально, но достаточно часто, чтобы использовать это как опорный сигнал для содержательной интерпретации.

Примеры серий с высокой согласованностью

Код	regime consistency	interpretability consistency	top beta consistency	reading mode consistency
`21`	1.000000	0.842105	0.902256	0.842105
`18`	1.000000	0.827068	0.947368	0.827068
`31`	1.000000	0.819549	0.879699	0.819549
`16`	1.000000	0.819549	0.909774	0.819549
`15`	1.000000	0.812030	0.984962	0.812030

Комментарий

Этот baseline-consistency уже поддерживает важный эмпирический тезис:

> даже если конкретное окно редко допускает прямую регрессионную интерпретацию, режим и тип допустимого чтения на реальных промышленных рядах всё же оказываются достаточно устойчивыми, чтобы строить на них дальнейшие отраслевые кейсы.

В то же время это ещё не финальный `A5`, потому что пока не проверена устойчивость по:

- `W = 36` и `W = 48`;
- `L = 6`;
- сравнительному анализу между `adj_smoothed`, `adj_unsmoothed` и `raw`.

Expanded consistency: `W = 24, 36, 48`, `L = 6`

Расширенные артефакты:

- overall_summary.csv
- series_consistency.csv

- variant_consistency.csv
- variant_consistency.png

Интегральная expanded-сводка:

Метрика	Среднее значение
regime consistency	0.929731
interpretability consistency	0.747145
tool consistency	0.848679
top beta consistency	0.718697
top B consistency	0.709998
reading mode consistency	0.745210

Динамика по окнам:

Окно	regime consistency	interpretability consistency	tool consistency	top beta consistency	top B consistency
24	0.820189	0.643257	0.746761	0.691409	0.675252
36	0.881836	0.686302	0.795850	0.716195	0.711095
48	0.911185	0.724185	0.827445	0.736678	0.730822

Это один из самых важных реальных результатов на текущий момент:

> увеличение окна повышает не только долю интерпретируемых окон,
> но и устойчивость самого маршрута анализа.

При этом рост consistency идёт не за счёт “упрощения” динамики до базовой модели, а за счёт уменьшения доли вырожденных окон и повышения согласованности между режимом, интерпретируемостью и допустимой формой чтения.

Таким образом, expanded `A5` уже даёт хорошее эмпирическое основание для следующего шага — отраслевых карточек и deep-case анализа.

A6. Кейсовые отраслевые карточки

Артефакты

- case_summary.csv
- shock_summary.csv
- hierarchy_summary.csv
- case_cards.md
- case_overview.png

Для кейсовых карточек был взят следующий стартовый набор отраслей:

- ПРОМ — промышленность в целом;
- `06` и `06.1` — нефть и газ;
- `10` — пищевые продукты;
- `35.1+35.3` — производство, передача и тепло;
- `21` — лекарства;
- `26` — компьютеры и электроника;
- `38` — отходы.

Интегральная сводка по кейсам

Код	Интерпрет.	Plateau	Дом. режим	Дом. контур	mean R2	mean B_sum
ПРОМ	0.055	0.915	`plateau_degenerate`	`do_not_read`	0.415	0.0011
`06`	0.366	0.614	`plateau_degenerate`	`do_not_read`	0.284	0.0016
`06.1`	0.366	0.614	`plateau_degenerate`	`do_not_read`	0.284	0.0016
`10`	0.708	0.116	`turbulent_informative`	`phase_caution`	0.580	0.0049
`21`	0.799	0.000	`turbulent_informative`	`phase_caution`	0.434	0.0008
`26`	0.774	0.000	`turbulent_informative`	`phase_caution`	0.493	0.0016
`35.1+35.3`	0.711	0.036	`turbulent_informative`	`phase_caution`	0.443	-0.0030
`38`	0.766	0.000	`turbulent_informative`	`phase_caution`	0.323	-0.0003

Что здесь видно сразу

1. Агрегированный ряд ПРОМ почти целиком вырождается в `plateau_degenerate`. Это подтверждает предыдущие разделы: наиболее агрегированные ряды плохо подходят для буквального чтения короткой лаговой структуры.
2. Нефтяной контур `06 / 06.1` ведёт себя почти так же, как промышленность в целом: высокая plateau-доля и доминирующий режим `do_not_read`.
3. Отрасли `10`, `21`, `26`, `35.1+35.3` и `38` оказываются содержательно более информативными, но и они не переходят в “чистый memory-reading”. Их нормальный контур чтения — это `phase_caution`.
4. Во всех кейсах доминирующий фактор по `|beta|` остаётся `X_n`. Это сильный эмпирический сигнал: на реальных месячных `IPP`-рядах текущий уровень обычно важнее, чем устойчивая и явно доминирующая память первого лага.

Шоковые точки 2020 и 2022

Наиболее показательные наблюдения по шокам таковы:

Код	2020 режим	2020 контур	2022 режим	2022 контур
ПРОМ	`turbulent_informative`	`phase_caution`	`plateau_degenerate`	`do_not_read`

Код	2020 режим	2020 контур	2022 режим	2022 контур
06	turbulent_informative	caution	plateau_degenerate	do_not_read
06.1	turbulent_informative	caution	plateau_degenerate	do_not_read
10	turbulent_informative	caution	turbulent_informative	caution
21	turbulent_informative	caution	turbulent_informative	caution
26	turbulent_informative	caution	turbulent_informative	caution
35.1+35.3	turbulent_informative	beta_bsum_caution	turbulent_informative	do_not_read
38	turbulent_informative	caution	turbulent_informative	caution

Это даёт уже содержательную отраслевую картину:

1. Для агрегатов и нефтяного контура 2022 выглядит как более “закрывающий” шок: окно чаще перестаёт быть читаемым и уходит в `do_not_read`.
2. Для пищевой, фармацевтической, электронной и отходной отраслей и 2020, и 2022 остаются турбулентными, но ещё информативными эпизодами.
3. Энергетический кейс `35.1+35.3` выделяется отдельно: в 2020 он ещё допускает осторожное чтение через `beta_bsum_caution`, а к 2022 уходит в более жёсткий режим `do_not_read`.

Representative cards

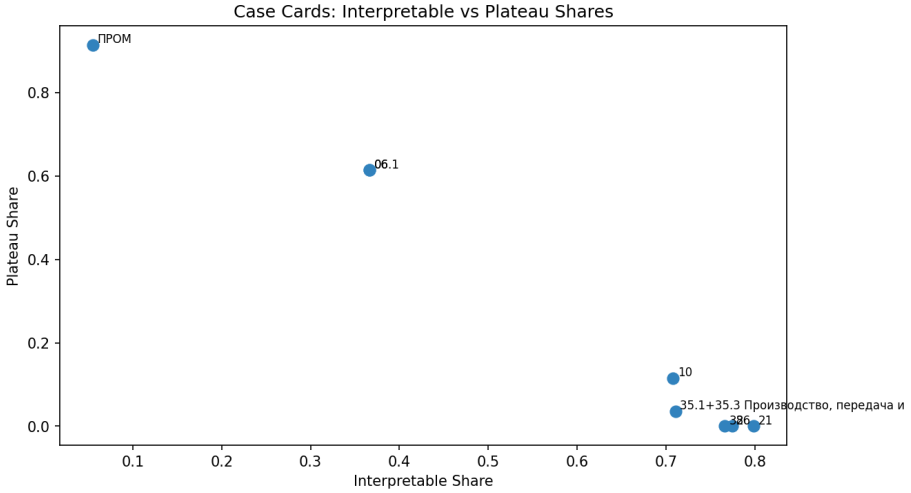

Figure 6: Case Overview

Общая карта кейсов

Промышленность в целом

Лекарственные средства

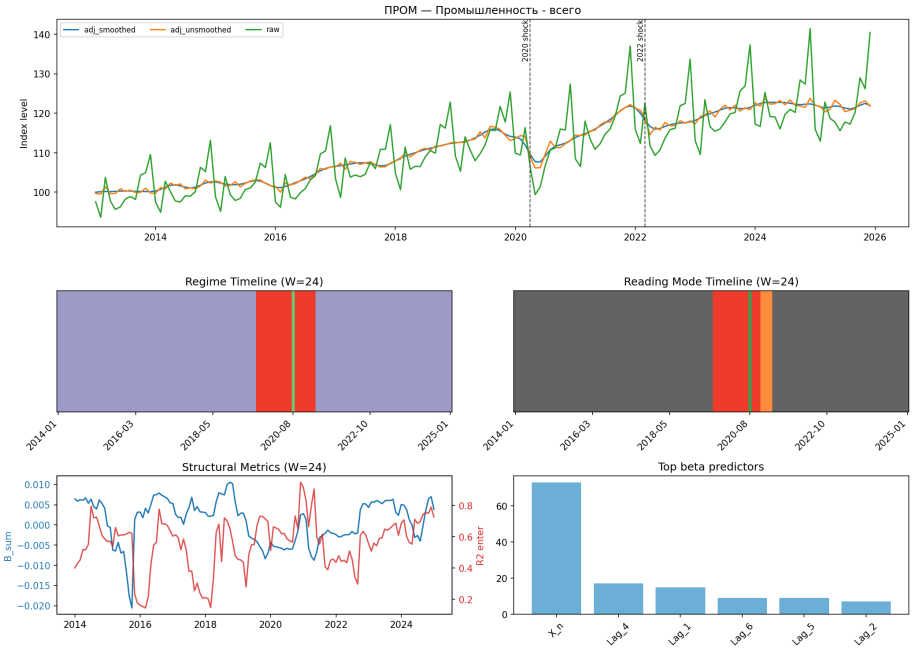

Figure 7: PROM Card

Figure 8: 21 Card

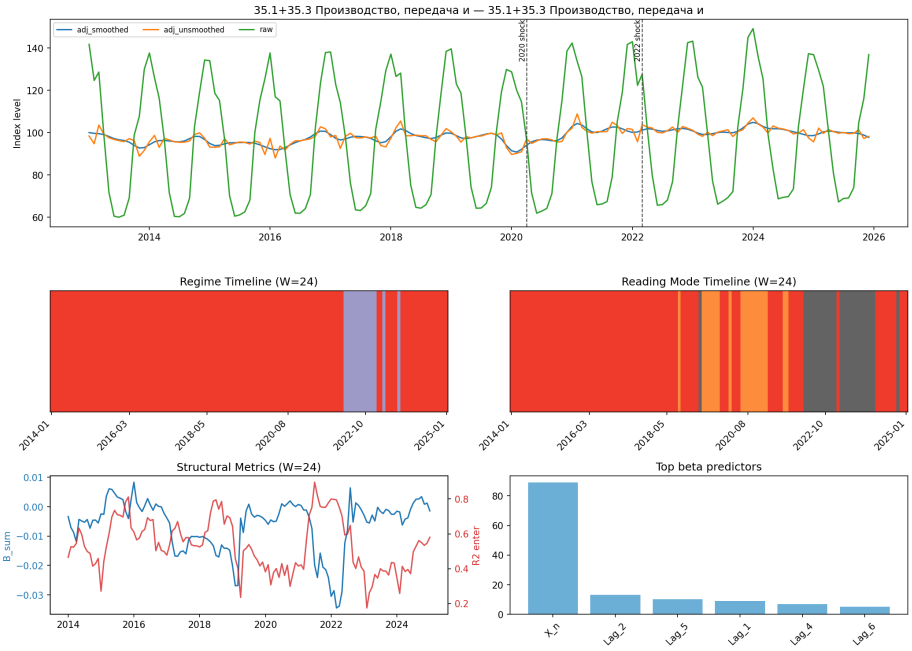

Figure 9: 35 Card

Энергетический кейс `35.1+35.3`

Методологический смысл `A6`

Отраслевые карточки подтверждают центральный результат всей real-data линии:

> даже там, где окно достаточно часто оказывается интерпретируемым, нормальным режимом чтения реального промышленного ряда остаётся не “прямая память”, а осторожное фазово-структурное чтение.

Именно поэтому маршрут главы 2 сохраняется на эмпирике почти без изменений:

1. сначала определить режим окна;
2. затем проверить, не вырождено ли оно;
3. потом выбрать допустимый контур анализа;
4. и только после этого читать `beta`, `B_sum`, `ENTER` и `Stepwise`.

Что делать дальше

Первый круг по промышленным индексам теперь закрыт на уровне `A0-A6`. Следующие логичные шаги:

1. переходить к линии выручки (`B1` и `B2`) на уже подготовленном годовом корпусе;

2. после этого строить bridge-case между `IPP` и выручкой только для ограниченного набора отраслей;
3. в текст диплома переносить real-data линию уже как отдельную главу, опираясь на `results.md` и сохранённые карточки.