Оглавление

2 ЧИСЛЕННОЕ МОДЕЛИРОВАНИЕ И ИССЛЕДОВАНИЕ ВОЗМОЖНОСТЕЙ РЕГРЕССИОННОГО АНАЛИЗА ДЛЯ ИДЕНТИФИКАЦИИ НЕЛИНЕЙНЫХ ПРОЦЕССОВ 4

2.1 Постановка задачи и методология вычислительного эксперимента . . . 4

2.1.1 Цель и гипотеза вычислительного эксперимента . . . 4

2.1.2 Три семейства исследуемых моделей . . . 4

2.1.3 Что именно сравнивается . . . 5

2.1.4 Метрики качества и критерии интерпретации . . . 5

2.1.5 Дизайн вычислительного эксперимента . . . 6

2.2 Описание базовой модели и сценариев эксперимента . . . 7

2.2.1 Устойчивый режим . . . 7

2.2.2 Циклический режим . . . 8

2.2.3 Хаотический режим . . . 8

2.2.4 Итог по базовой модели . . . 11

2.2.5 Методологический тест: стадии жизненного цикла и короткие окна . . . 11

2.3 Описание модели с запаздыванием и сценариев эксперимента 13

2.3.1 Чистый случай распознавания памяти ($g = 0.2$) . . . 14

2.3.2 Переход к неустойчивости ($g = 1.05$) . . . 14

2.3.3 Высокий fit и сломанный прогноз ($g = 1.25$) . . . 17

2.3.4 Сравнение с базовой моделью . . . 18

2.3.5 Выводы по запаздывающей модели . . . 19

2.3.6 Детализация запаздывающей модели на коротких выборках (стадии + скользящие окна) . . . 19

2.4 Описание смешанной модели и параметров эксперимента . . . 20

2.4.1 Положительная память: структурная идентификация в устойчивом режиме . . . 21
2.4.2 Отрицательная память: стимулирующий эффект предыстории . . . 21
2.4.3 Зона деградации интерпретации . . . 23
2.4.4 Итоговая таблица по смешанной модели . . . 23
2.4.5 Выводы по смешанной модели . . . 25
2.4.6 Дополнение: смешанная модель на коротких выборках (стадии + скользящие окна) . . . 26
2.4.7 Введение к серии дополнительных экспериментов 2.4.1-2.4.3 . . . 28
2.4.8 Сопоставление прямой идентификации параметров отображения и структурной регрессии . . . 29
2.4.9 Диагностика режима и границы интерпретируемости короткого окна . . . 30
2.4.10 Сравнение основных контуров анализа и проверки устойчивости . . . 31
2.4.11 Итоговая схема интерпретации результатов . . . 32
2.5 ЗАКЛЮЧЕНИЕ И ОБЩИЕ ВЫВОДЫ ПО РЕЗУЛЬТАТАМ МОДЕЛИРОВАНИЯ . . . 32
2.5.1 Общий вывод главы . . . 32
2.5.2 Ограничения главы 2 . . . 33

3 ПЕРЕНОС РЕЖИМНО-ЗАВИСИМОГО АППАРАТА НА РЕАЛЬНЫЕ ДАННЫЕ 34
3.1 Источники данных, ограничения и гипотезы эмпирической части . . . 34
3.1.1 Корпус 1: индексы промышленного производства . . . 34
3.1.2 Корпус 2: выручка стабильных компаний . . . 34
3.1.3 Почему корпуса нельзя напрямую объединять . . . 34
3.1.4 Ограничения данных . . . 35
3.1.5 Гипотезы эмпирической части . . . 35
3.2 Дизайн эмпирической части . . . 35
3.3 Предварительная проверка переносимости на промышленных индексах . . . 36

3.3.1 Вопрос, данные и главный результат 36
3.3.2 Ограничение этого шага 36
3.4 Группы компаний по выручке 37
3.4.1 Вопрос и данные 37
3.4.2 Режимное чтение 37
3.4.3 Главный результат 37
3.4.4 Ограничение 38
3.5 Отраслевой подкорпус выручки 39
3.5.1 Формирование корпуса 39
3.5.2 Полные интервалы и короткие окна 40
3.5.3 Шоки 2020 и 2022 43
3.6 Общие выводы по главе реальных данных и практическая значимость 43
3.6.1 Основные выводы главы 44
3.6.2 Практическая значимость 44
3.6.3 Ограничения и итоговый вывод 45

A Приложение А. Дополнительные synthetic-эксперименты и проверки устойчивости 46

B Приложение Б. Расширенная линия промышленных индексов 47

C Приложение В. Дополнительные таблицы по линии выручки 48

2 ЧИСЛЕННОЕ МОДЕЛИРОВАНИЕ И ИССЛЕДОВАНИЕ ВОЗМОЖНОСТЕЙ РЕГРЕССИОННОГО АНАЛИЗА ДЛЯ ИДЕНТИФИКАЦИИ НЕЛИНЕЙНЫХ ПРОЦЕССОВ

2.1 Постановка задачи и методология вычислительного эксперимента

2.1.1 Цель и гипотеза вычислительного эксперимента

Цель данной главы состоит в том, чтобы проверить гипотезу в рамках вычислительного эксперимента: в каких режимах линейный регрессионный анализ способен правильно читать структуру детерминированного нелинейного процесса, а в каких режимах высокий fit начинает маскировать ложные лаги, вырождение окна или потерю прогностической устойчивости.

Вычислительный эксперимент проводится на синтетических траекториях, где закон генерации данных задан заранее. Это позволяет оценивать результаты эконометрического анализа в контролируемых условиях, сопоставляя найденную регрессионную структуру с истинным механизмом динамики.

2.1.2 Три семейства исследуемых моделей

В работе рассматриваются три типа дискретных отображений, задающих разные варианты реакции системы на ограничение роста. Во всех моделях $K = 1$.

1. Базовая модель (мгновенная реакция)

$$X_{n+1} = X_n + AX_n(K - X_n)$$

Темп прироста определяется только текущим состоянием X_n. Истинная структура памяти отсутствует.

2. Модель с запаздыванием

$$X_{n+1} = X_n + gX_n(K - X_{n-1})$$

Темп прироста зависит от предыдущего состояния X_{n-1}. Истинная структура содержит лаг 1.

3. Смешанная модель

$$X_{n+1} = X_n + qX_n(K - X_n - \gamma X_{n-1})$$

Динамика определяется одновременно текущим уровнем и лагом 1. Это наиболее общий случай, где возможна конкуренция факторов и усиление мультиколлинеарности.

2.1.3 Что именно сравнивается

Для каждой модели генерируются траектории в нескольких режимах: от устойчивого роста до колебаний, границы хаоса и развитого динамического хаоса. Далее на этих траекториях строятся регрессионные модели для темпа прироста

$$\omega_{n+1} = \frac{X_{n+1} - X_n}{X_n},$$

где в качестве предикторов выступают текущий уровень и лаги ряда. Сравниваются:

1. качество подгонки регрессионной модели;
2. способность метода выделить истинные структурные переменные;
3. склонность метода включать ложные лаги;
4. устойчивость краткосрочного и итеративного прогноза;
5. поведение оценок на длинных траекториях и на коротких окнах.

2.1.4 Метрики качества и критерии интерпретации

В качестве основных показателей используются:

1. R^2 и adjusted R^2 как меры локального качества подгонки;
2. знаки и величины коэффициентов B;
3. стандартизированные коэффициенты β для ранжирования факторов;
4. частота ложных лагов и доля правильного восстановления структуры;

5. устойчивость прогноза при итеративном продолжении траектории;
6. признаки вырождения окна: малая дисперсия, коллинеарность, исчезновение сигнала.

Успех метода в данной главе понимается не как получение максимального fit само по себе, а как совпадение статистического вывода с истинной структурой модели. Неуспехом считается ситуация, когда регрессия демонстрирует высокое качество подгонки, но:

1. выбирает ложные лаги;
2. теряет истинную переменную;
3. становится неустойчивой на коротких окнах;
4. даёт формально хорошее, но содержательно пустое прогнозное продолжение.

2.1.5 Дизайн вычислительного эксперимента

Единый протокол главы включает четыре шага.

1. Генерация траекторий для выбранных параметров и режимов.
2. Фазовая диагностика динамики.
3. Построение регрессионных моделей ENTER и STEPWISE, а в дополнительных экспериментах также альтернативных диагностических контуров.
4. Сравнение полученной регрессионной структуры с истинным законом динамики и анализ прогностической устойчивости.

Краткий паспорт эксперимента приведён в таблице.

Модель	Истинная структура	Основные режимы	Ожидание от регрессии	Основной риск ошибки
Базовая	только X_n	устойчивый рост, колебания, хаос	выделение текущего уровня без ложной памяти	принятие цикличности за глубокую память
Запаздывающая	доминирует X_{n-1}	рост, затухающие колебания, бифуркация, хаос	выделение лага 1 как ключевого фактора	потеря истинного лага из-за шума и коллинеарности

Модель	Истинная структура	Основные режимы	Ожидание от регрессии	Основной риск ошибки
Смешанная	совместно X_n и X_{n-1}	устойчивость, цикл, хаос, режимы при $\gamma < 0$	восстановление конкурирующих факторов и их знаков	ложная подмена структуры дальними лагами

Таким образом, глава 2 строится как последовательная проверка того, где линейная регрессия действительно восстанавливает структуру нелинейного процесса, а где она должна использоваться только как локальный диагностический инструмент.

2.2 Описание базовой модели и сценариев эксперимента

В данном подразделе рассматривается базовое логистическое отображение

$$X_{n+1} = X_n + AX_n(K - X_n), \qquad K = 1,$$

в котором истинная структура темпа прироста определяется только текущим состоянием X_n. Для проверки регрессионного аппарата выбраны пять сценариев: $AK = 0.8$, $AK = 1.5$, $AK = 2.2$, $AK = 2.52$ и $AK = 2.8$. Они охватывают устойчивое равновесие, цикл и развитый хаос.

2.2.1 Устойчивый режим

Сценарии $AK = 0.8$ и $AK = 1.5$ дают близкий по смыслу результат, поэтому их удобно рассматривать вместе. В обоих случаях траектория сходится к стационарному состоянию, а фазовый портрет согласуется с детерминированной природой процесса и сохраняет параболическую форму $X_{n+1} = f(X_n)$.

Для этих режимов регрессия работает корректно: метод STEPWISE выделяет только текущий уровень X_n, коэффициент детерминации равен $R^2 \approx 1$, а оценка влияния X_n совпадает с теоретическим значением в пределах вычислительной точности. Итеративный прогноз также остаётся устойчивым и на рассматриваемом горизонте практически не расходится с истинной траекторией.

Следовательно, в устойчивом режиме линейная регрессия действительно способна восстановить линейную структуру темпа прироста и не создаёт ложной памяти.

2.2.2 Циклический режим

При $AK = 2.2$ система переходит к устойчивому циклу периода 2, а при $AK = 2.52$ — к более сложному циклу на границе хаоса. Для регрессионного анализа это принципиально иной класс ситуаций: качество подгонки остаётся очень высоким, но структура модели начинает искажаться.

В режиме $AK = 2.2$ алгоритм STEPWISE выбирает не только X_n, но и Lag_2. Содержательно это ложный результат: уравнение не содержит зависимости от второго лага, а его появление вызвано тем, что в цикле периода 2 значения X_n и X_{n-2} почти совпадают. В режиме $AK = 2.52$ эффект усиливается: в модель попадают Lag_4 и статистические дубли более дальних лагов. Тем самым высокая мультиколлинеарность циклических значений начинает маскироваться под глубокую память.

Именно циклический режим даёт первый устойчивый контрпример наивной интерпретации высокого R^2: хорошая подгонка ещё не означает правильное восстановление структуры.

2.2.3 Хаотический режим

Сценарий $AK = 2.8$ задаёт развитый динамический хаос. Временной ряд визуально напоминает шум, однако фазовый портрет по-прежнему согласуется с детерминированной природой процесса и сохраняет геометрию логистического отображения.

Здесь возникает ключевой парадокс базовой модели. С одной стороны, регрессия по-прежнему даёт $R^2 \approx 1$, поскольку темп прироста сохраняет линейную зависимость от X_n. Иными словами, метод способен восстановить линейную структуру темпа прироста даже в хаотическом режиме. С другой стороны, итеративный прогноз быстро теряет фазовую синхронизацию с истинной траекторией. На коротком горизонте совпадение сохраняется, но затем чувствительность к начальным условиям делает долгосрочный точечный прогноз неустойчивым.

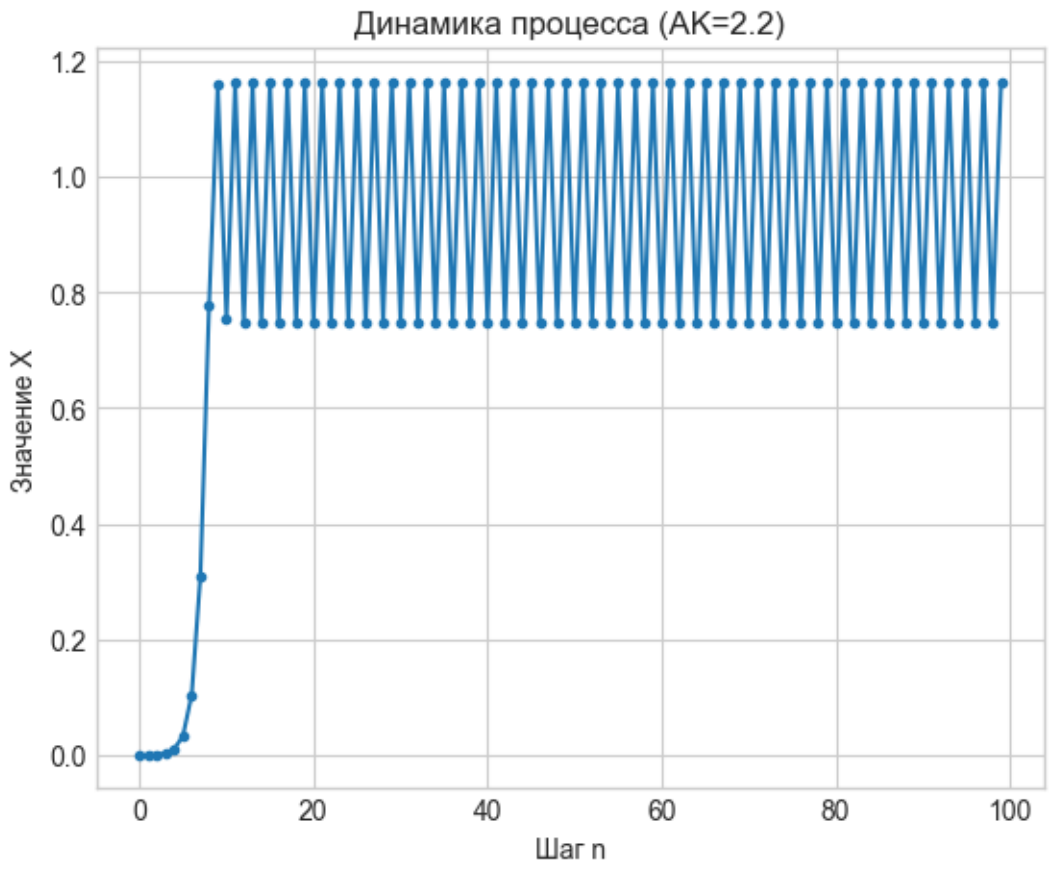

Рис. 2.1 – dyn_phas_22

Тем самым хаос выявляет второе фундаментальное ограничение регрессионного подхода: корректное описание локального закона ещё не гарантирует пригодность далёкого итеративного прогноза.

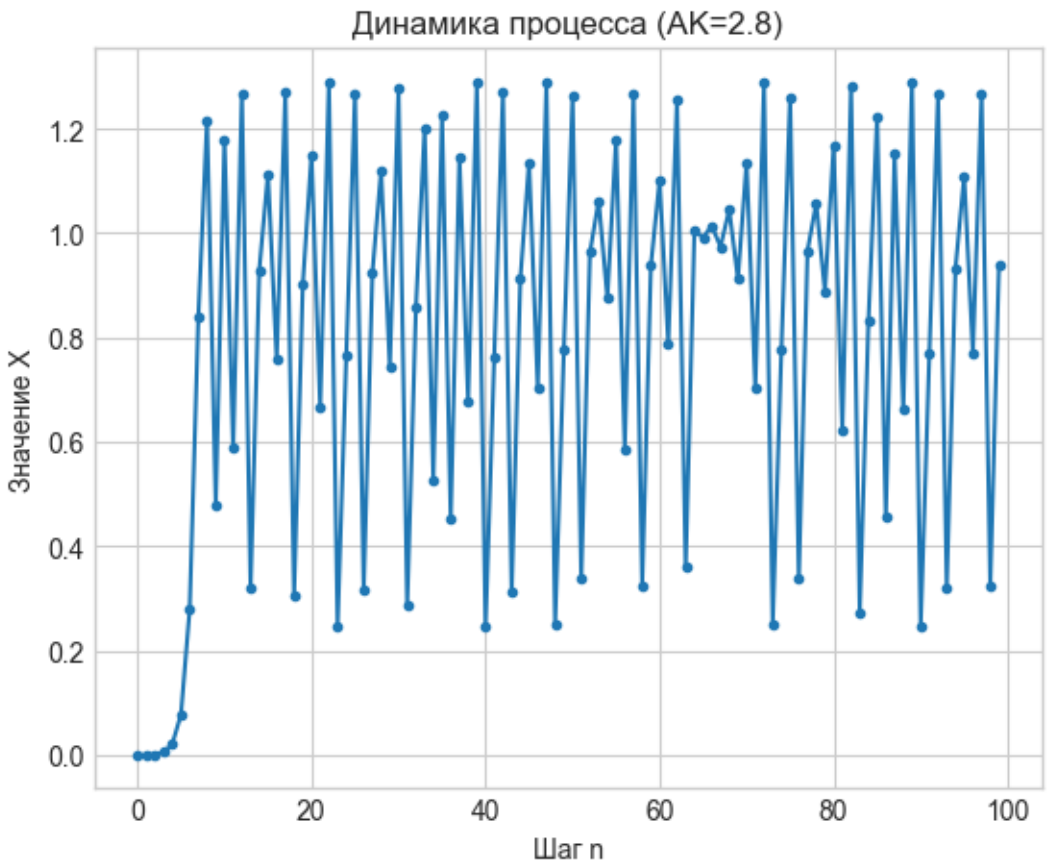
Динамика процесса (AK=2.8)
Значение X
Шаг n
0.0
0.2
0.4
0.6
0.8
1.0
1.2
0
20
40
60
80
100

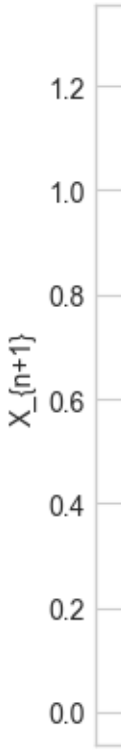
X_{n+1}
0.0
0.2
0.4
0.6
0.8
1.0
1.2

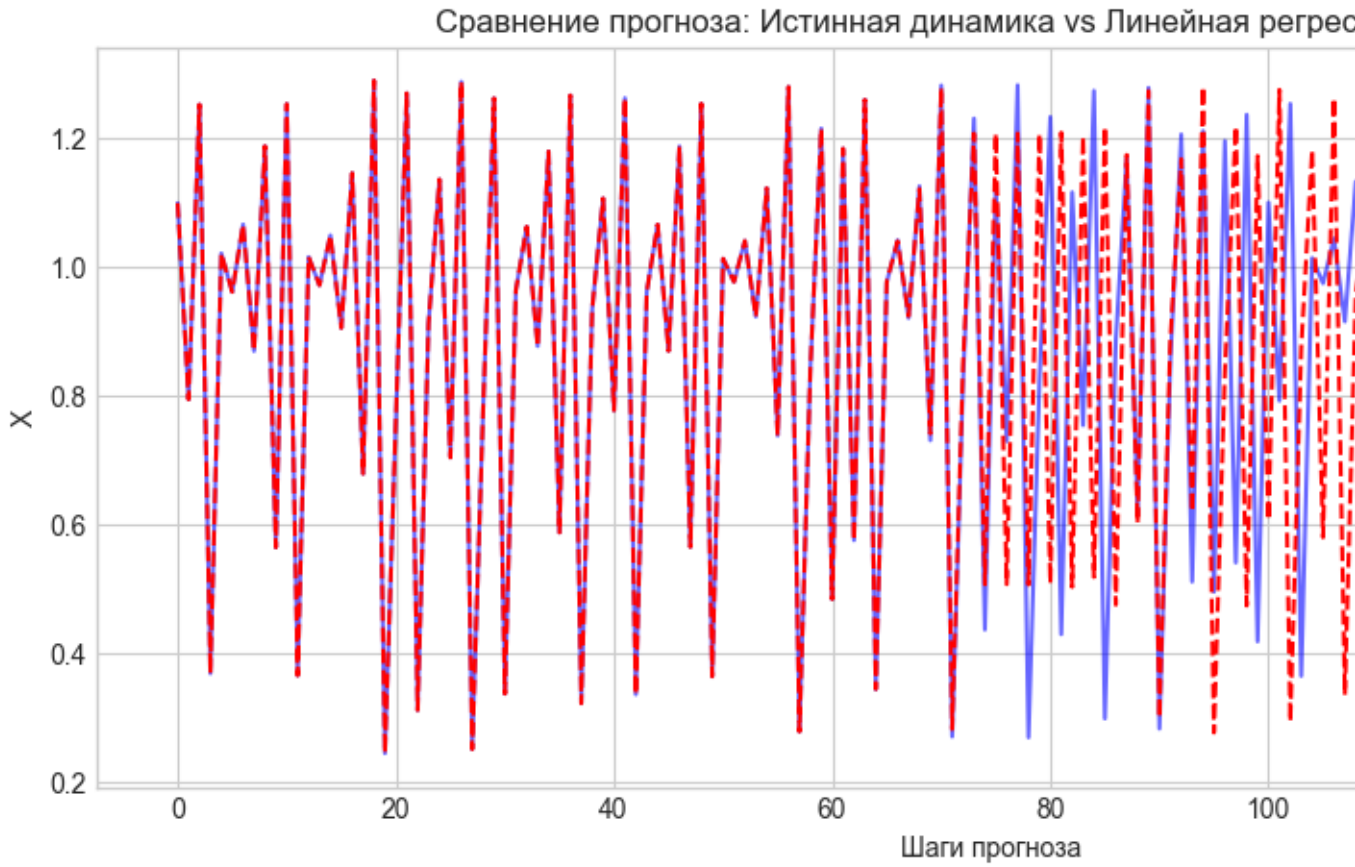
Сравнение прогноза: Истинная динамика vs Линейная регрес
X
Шаги прогноза
0.2
0.4
0.6
0.8
1.0
1.2
0
20
40
60
80
100

2.2.4 Итог по базовой модели

Основные результаты удобно свести в таблицу.

Режим	Истинный фактор	Что выбрал Stepwise	Ложные лаги	Работает ли прогноз
Устойчивое равновесие ($AK = 0.8; 1.5$)	X_n	X_n	нет	да, на всём рассматриваемом горизонте
Цикл ($AK = 2.2$)	X_n	X_n, Lag_2	да	локально, но структура читается неверно
Сложный цикл ($AK = 2.52$)	X_n	X_n, Lag_4, дальние дубли	да	ограниченно
Хаос ($AK = 2.8$)	X_n	X_n	нет в базовой структуре, но прогноз неустойчив	только на коротком горизонте

По базовой модели можно сделать три вывода. Во-первых, в устойчивом режиме регрессия правильно восстанавливает структуру без ложной памяти. Во-вторых, цикл и граница хаоса показывают, что STEPWISE склонен принимать периодичность за наличие глубоких лагов. В-третьих, хаос демонстрирует разрыв между локальной идентификацией и долгосрочным прогнозом: высокий R^2 совместим с потерей прогностической устойчивости.

2.2.5 Методологический тест: стадии жизненного цикла и короткие окна

Данный блок вводится не как второй самостоятельный анализ базовой модели, а как методологический тест коротких выборок. Его задача состоит в следующем: **проверка того, не путает ли исследователь смену локального диапазона ряда со структурным сдвигом закона**.

Для этого одна и та же S-образная траектория разбивается на стадии жизненного цикла и одновременно просматривается скользящим окном длины 25. Рассматривается регрессия темпа прироста

$$\omega_{n+1} = \frac{X_{n+1} - X_n}{X_n}$$

на текущий уровень и лаги $X_{n-1}, \ldots, X_{n-10}$ методами ENTER и STEPWISE.

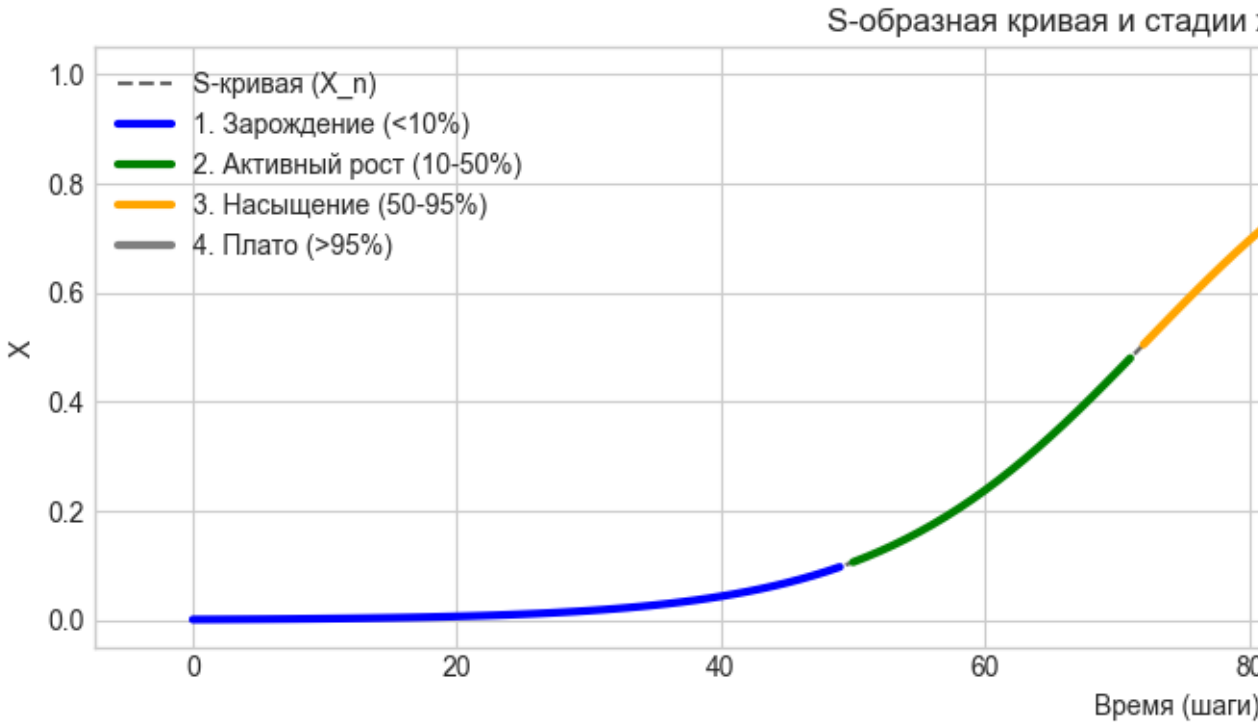

Рисунок показывает, что S-кривая естественным образом распадается на локальные участки с разной геометрией: зарождение, активный рост, насыщение и плато. Именно эта смена локальной геометрии окна и проверяется далее.

Результаты по стадиям сведены в таблицу.

Стадия	Интервал	n	ENTER R^2	STEP R^2	$B(X_n)$	$\beta(X_n)$	Stepwise
Зарождение	0–50	39	1.000000	1.00	−0.099676	−0.994135	только X_n
Активный рост	50–72	11	1.000000	1.00	−0.099873	−1.004154	только X_n
Насыщение	72–101	18	0.999971	1.00	−0.100010	−1.000580	только X_n
Плато	101–150	38	1.000000	1.00	−0.070943	−0.640854	только X_n

Таблица показывает два результата. Во-первых, структурная идентификация остаётся устойчивой: STEPWISE на всех стадиях выбирает только X_n, что согласуется с отсутствием памяти в базовой модели. Во-вторых, на плато

стандартизированный вклад X_n уменьшается по модулю не из-за изменения закона, а из-за сжатия дисперсии и ослабления сигнала.

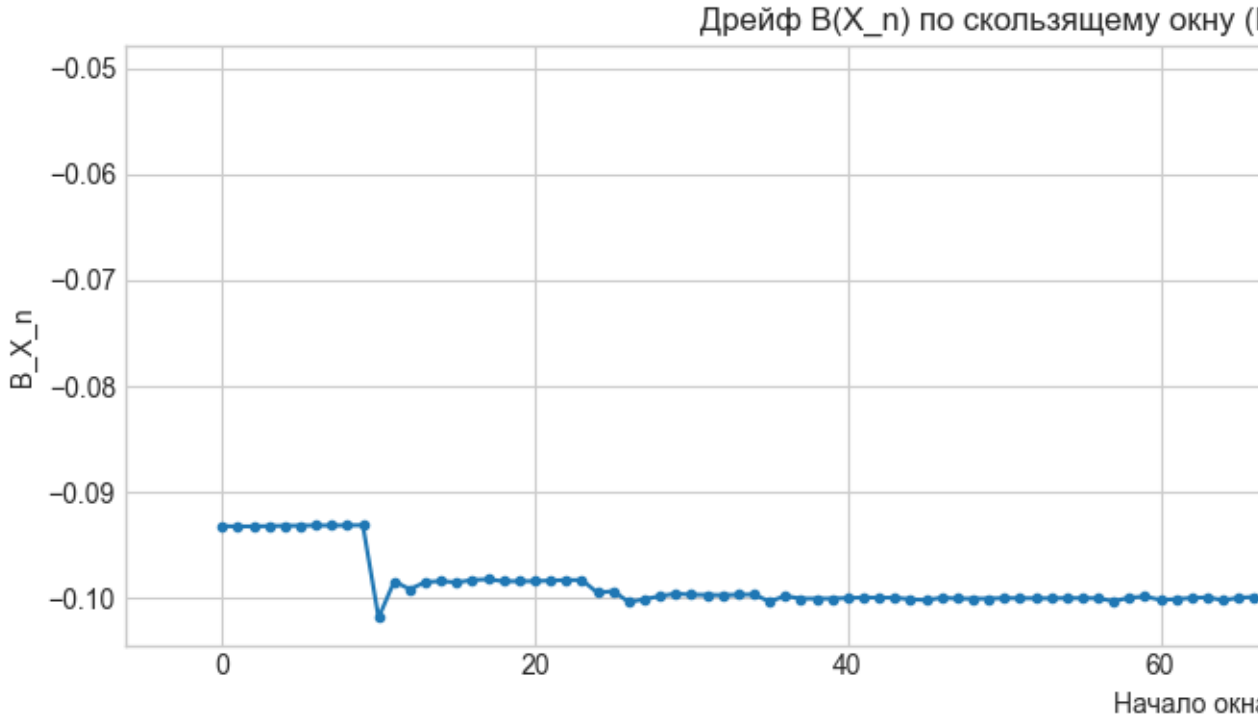

График скользящего окна делает этот эффект наглядным: при неизменном законе динамики оценки коэффициентов могут дрейфовать из-за локальной геометрии окна. В данном случае дрейф отражает смену диапазона и дисперсии X_n, а не реальный структурный сдвиг процесса.

Именно поэтому этот тест важен для всей последующей главы: он показывает, что даже в самой простой модели исследователь может принять локальную неоднородность короткого окна за изменение механизма роста. Для базовой модели такой вывод особенно полезен, поскольку здесь структура известна заранее и любые отклонения интерпретируются как чистый методический эффект.

2.3 Описание модели с запаздыванием и сценариев эксперимента

В данном подразделе рассматривается логистическая модель с запаздыванием

$$X_{n+1} = X_n + gX_n(K - X_{n-1}), \qquad K = 1,$$

в которой истинный фактор смещается с текущего состояния X_n на прошлое состояние X_{n-1}. Именно это смещение и является главным содер-

жательным отличием от базовой модели: задача регрессии состоит уже не в подтверждении роли текущего уровня, а в распознавании памяти.

Для проверки выбраны три опорных режима: $g = 0.2$ как чистый случай идентификации запаздывания, $g = 1.05$ как переход к неустойчивости и $g = 1.25$ как пример, где высокий fit сохраняется, а итеративный прогноз ломается. Режимы $g = 0.8$ и $g = 1.6$ используются ниже как дополнительные ориентиры: первый показывает чувствительность к вычислительным артефактам, второй — переход к режиму коллапса.

2.3.1 Чистый случай распознавания памяти ($g = 0.2$)

При $g = 0.2$ система монотонно движется к равновесию. Для данного режима регрессия решает главную структурную задачу: STEPWISE выбирает не X_n, как в базовой модели, а именно Lag_1, причём коэффициент при нём совпадает с теоретическим значением $-g$ в пределах вычислительной точности. Это означает, что линейный анализ корректно фиксирует наличие запаздывания как центрального механизма динамики.

На этом фоне особенно важен сравнительный вывод: по форме зависимости темпа прироста модель остаётся линейно читаемой, но смысл значимого фактора меняется. Тем самым модель с запаздыванием даёт первый явный тест того, способен ли регрессионный аппарат различать текущую реакцию и память.

2.3.2 Переход к неустойчивости ($g = 1.05$)

При $g = 1.05$ система теряет устойчивость. Фазовый портрет перестаёт быть почти линией и превращается в замкнутую петлю, что согласуется с увеличением размерности аттрактора и с инерционной природой процесса. Структурно регрессия по-прежнему указывает на Lag_1, однако прогностический смысл этой модели резко меняется.

В данном режиме коэффициент обратной связи по модулю превышает единицу, и линейный прогноз становится внутренне неустойчивым. Поэтому даже при очень высоком R^2 возникает резкая потеря устойчивости линейного прогноза: локальная идентификация памяти сохраняется, но итеративное продолжение быстро выходит из допустимого режима.

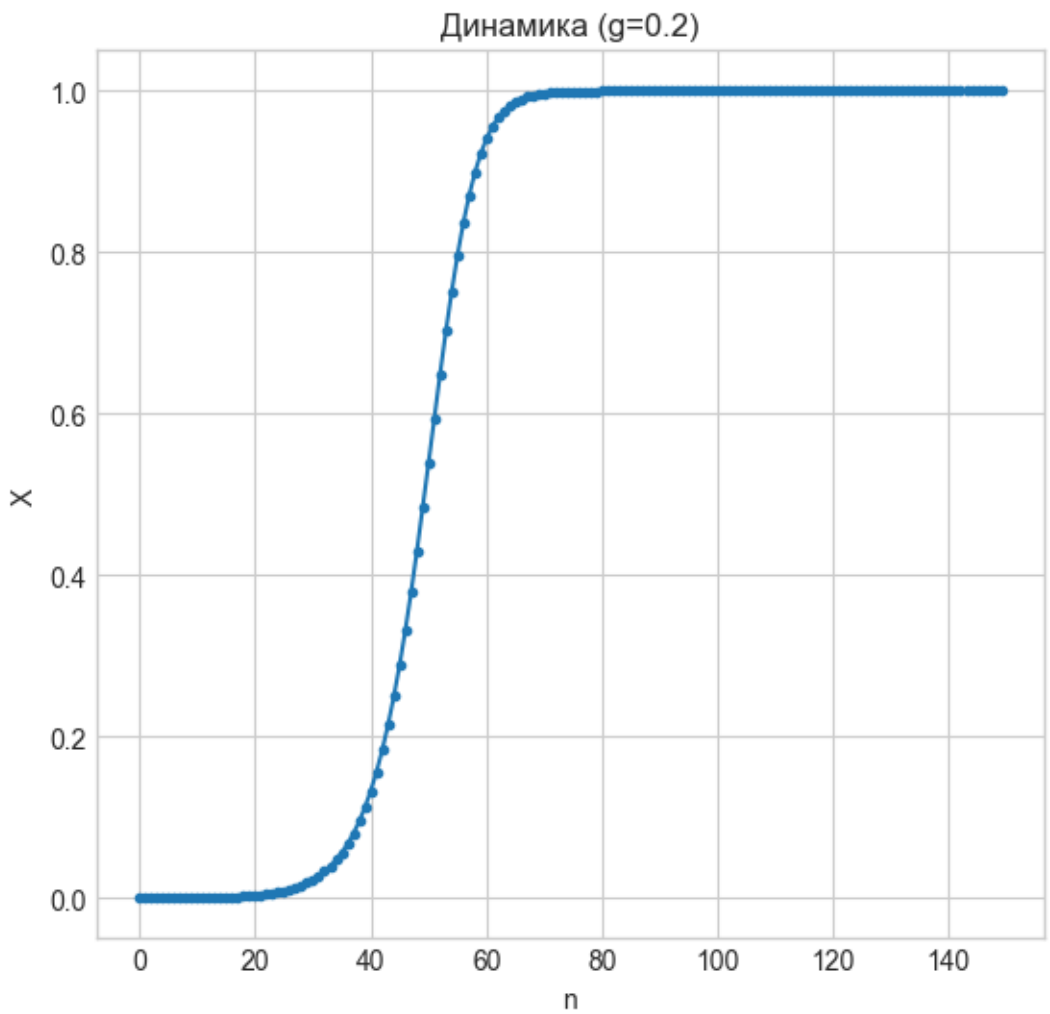

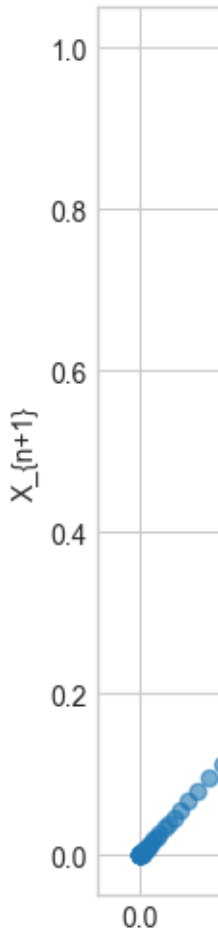

Рис. 2.2 – dyn_phas_02

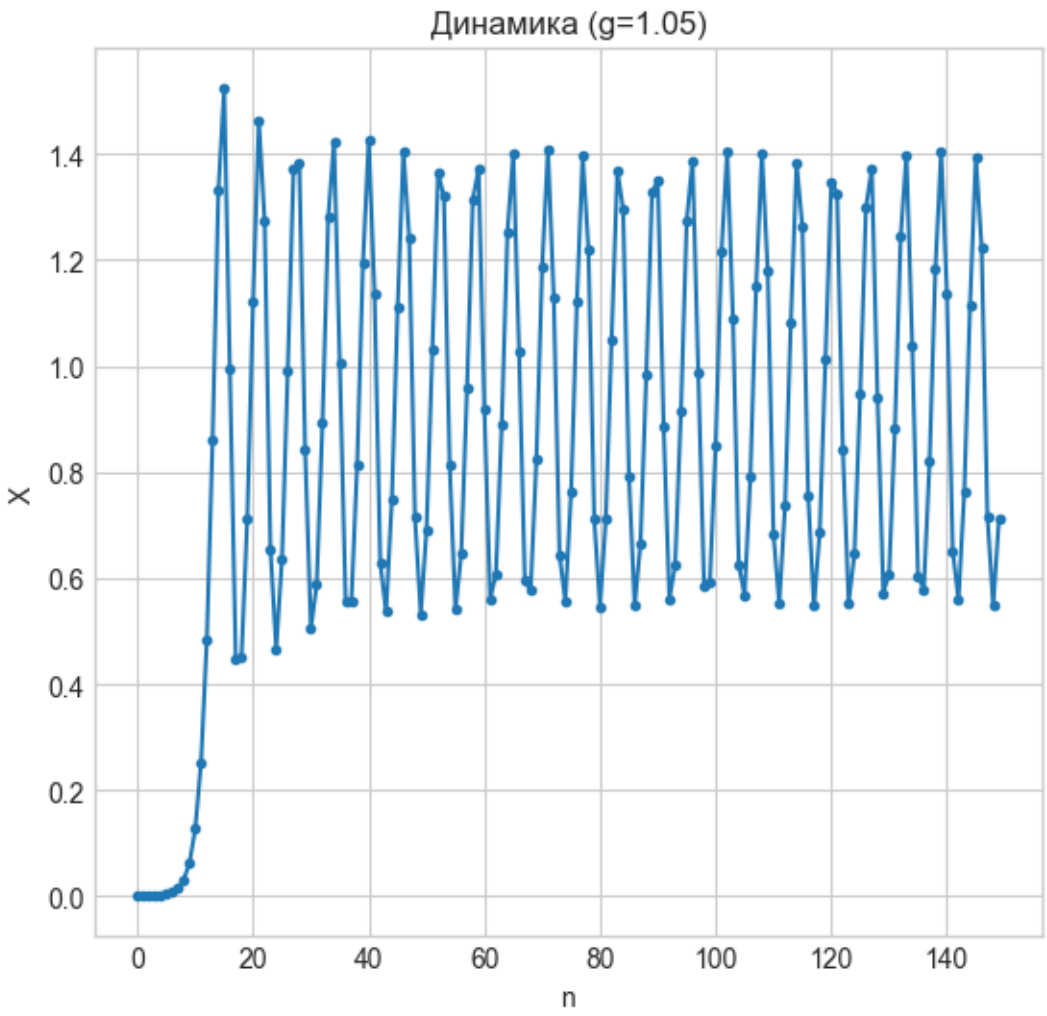
Динамика (g=1.05)
X
n
0.0
0.2
0.4
0.6
0.8
1.0
1.2
1.4
0
20
40
60
80
100
120
140

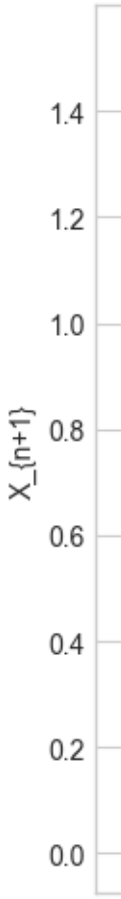
X_{n+1}
0.0
0.2
0.4
0.6
0.8
1.0
1.2
1.4

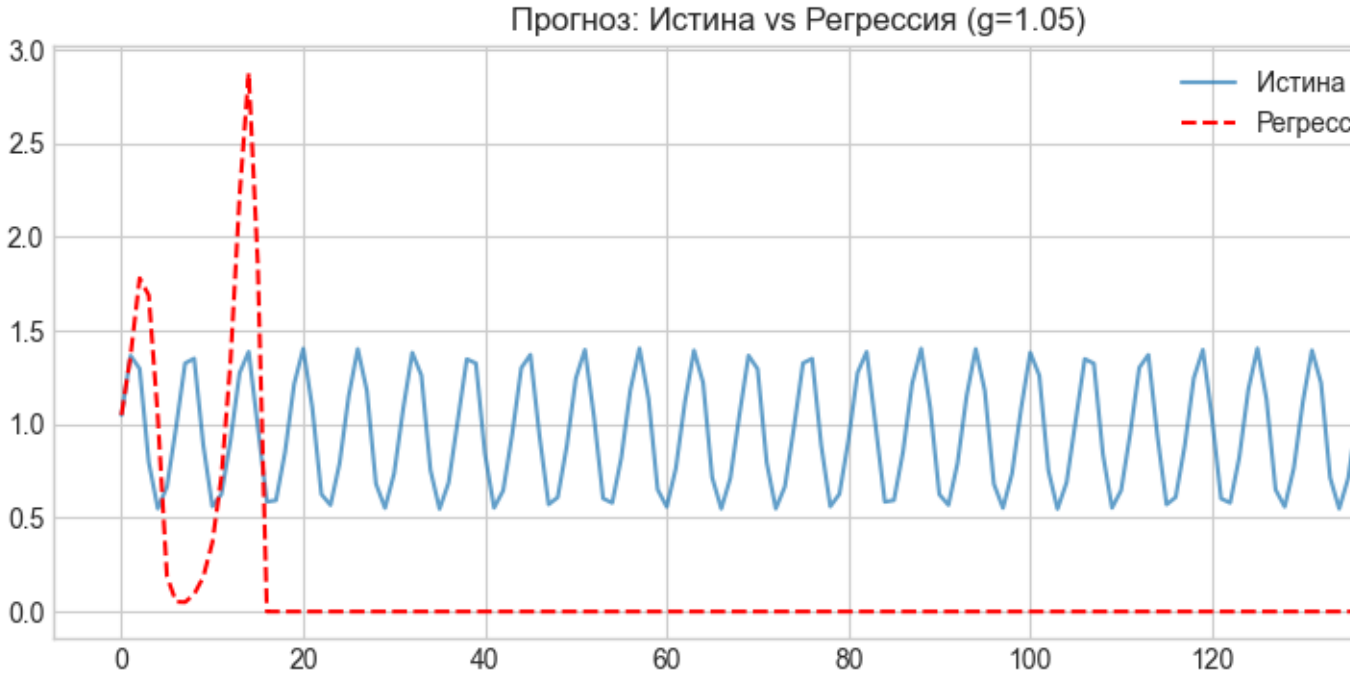
Прогноз: Истина vs Регрессия (g=1.05)
Истина
Регресс
0.0
0.5
1.0
1.5
2.0
2.5
3.0
0
20
40
60
80
100
120

2.3.3 Высокий fit и сломанный прогноз ($g = 1.25$)

Режим $g = 1.25$ наиболее наглядно показывает границы метода. Фазовый портрет демонстрирует уже сложную неустойчивую динамику, а регрессия всё ещё сохраняет высокий fit на обучающем отрезке. Тем не менее такой fit не обеспечивает устойчивого итеративного прогноза в данном режиме: траектория быстро расходится из-за чувствительности к фазе и отсутствия в линейной аппроксимации нелинейного механизма насыщения.

Именно этот сценарий задаёт главный практический вывод по модели с запаздыванием: правильное распознавание памяти и высокий R^2 ещё не гарантируют прогностическую пригодность модели.

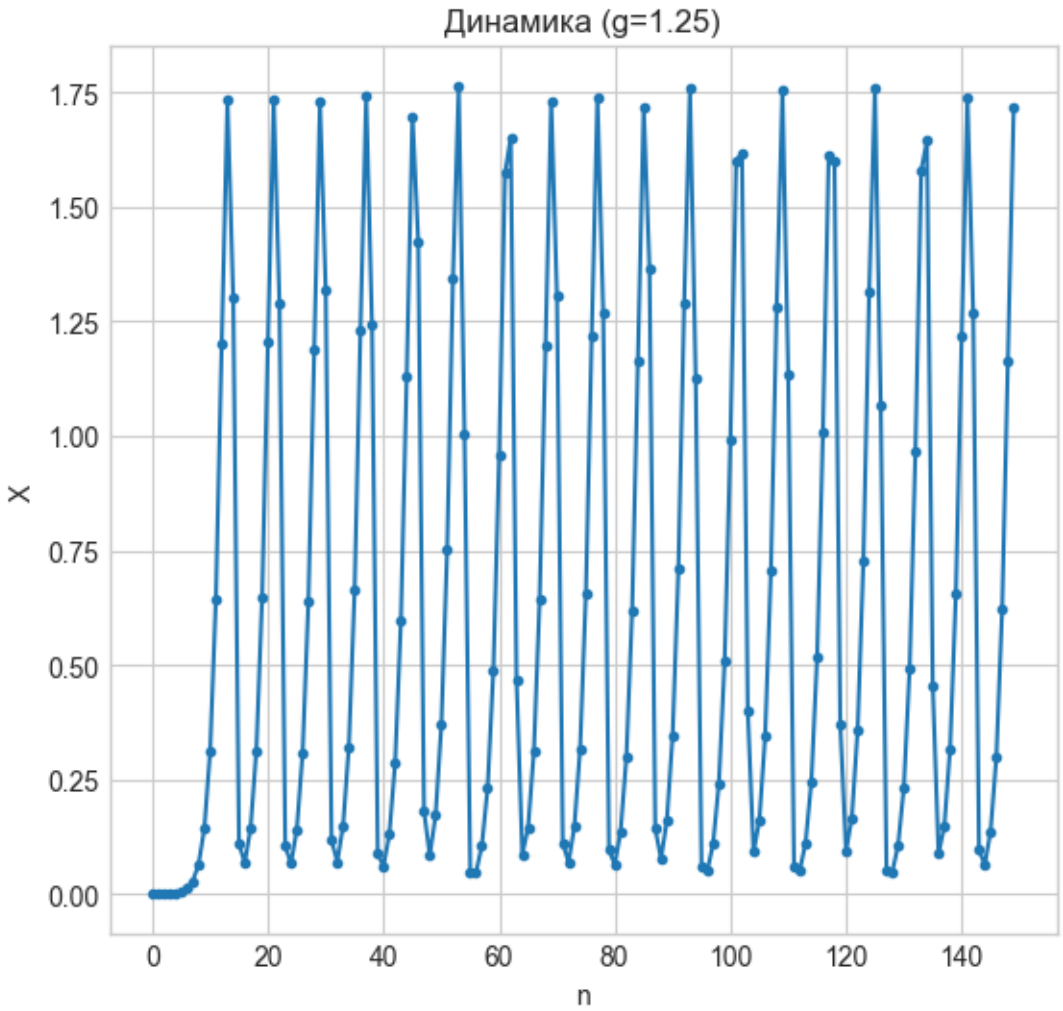

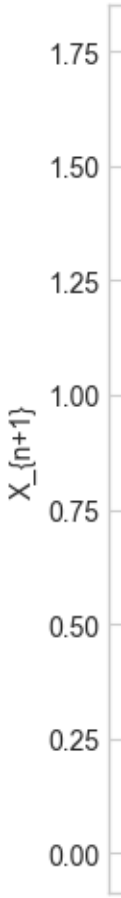

Дополнительные режимы $g = 0.8$ и $g = 1.6$ подтверждают ту же логику на промежуточных и крайних значениях параметра. При $g = 0.8$ возможны редкие вычислительные артефакты отбора, а при $g = 1.6$ система переходит в крайне неустойчивый режим коллапса, где регрессионное чтение практически теряет смысл.

2.3.4 Сравнение с базовой моделью

Модель	Истинный предиктор	Что диагностирует Stepwise	Тип фазового портрета	Основная прогнозная проблема
Базовая	X_n	текущий уровень	линия/парабола, затем кластеры и хаотическое облако	в хаосе локальный fit не гарантирует дальний прогноз
Запаздывающая	X_{n-1}	смещение на Lag_1	от почти линии к петле и разрыву петли	при $g > 1$ локальный fit не обеспечивает устойчивого итеративного прогноза

2.3.5 Выводы по запаздывающей модели

По модели с запаздыванием можно сделать три вывода. Во-первых, STEPWISE действительно фиксирует качественное смещение истинного фактора с X_n на Lag_1, то есть правильно распознаёт память. Во-вторых, фазовый портрет становится самостоятельным диагностическим признаком: переход от почти линейной формы к петле отражает потерю устойчивости. В-третьих, при $g > 1$ возникает уже знакомый по базовой модели разрыв между fit и прогнозом, но в более жёсткой форме: даже структурно корректная линейная аппроксимация не обеспечивает устойчивого итеративного прогноза в неустойчивом режиме.

2.3.6 Детализация запаздывающей модели на коротких выборках (стадии + скользящие окна)

Короткие выборки как зеркальный тест памяти

Этот подпункт нужен как прямое сопоставление с базовой моделью. В базовой модели короткие окна в основном сохраняли выбор X_n; в модели с запаздыванием тот же тест должен показать, сохраняется ли на окнах доминирование Lag_1.

Используются те же параметры локального анализа, что и выше: окно длины 25, лаги до 10, методы ENTER и STEPWISE. В качестве реперных режимов рассматриваются $g = 0.2$, $g = 0.8$ и $g = 1.25$.

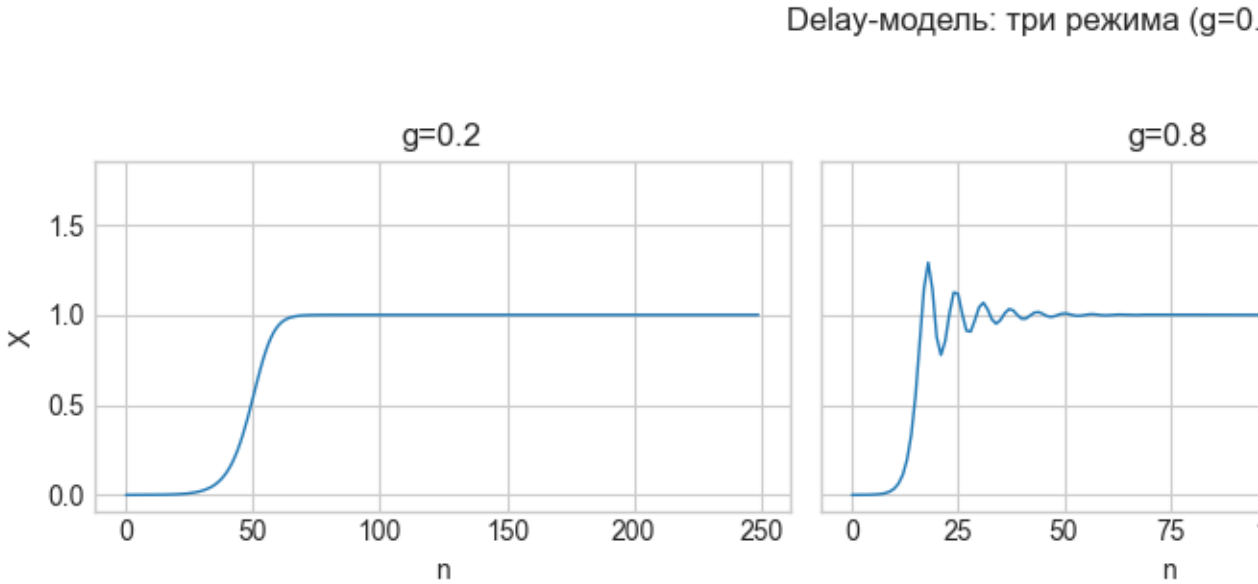

На траектории роста ($g = 0.2$) короткие окна действительно сохраняют

правильную структурную логику: STEPWISE чаще всего выбирает Lag_1, а не X_n. Тем самым короткая выборка не уничтожает возможность распознать память. По мере перехода к насыщению возрастает взаимозаменяемость лагов, и интерпретация отдельных коэффициентов становится менее устойчивой.

В промежуточном режиме $g = 0.8$ общая картина остаётся той же: доминирующим фактором по окнам остаётся Lag_1, но на отдельных фрагментах появляются дополнительные лаги, что отражает локальную фазовую чувствительность и вычислительные артефакты отбора.

В сложном режиме $g = 1.25$ возникает уже знакомая проблема: локально окна по-прежнему часто указывают на память, но при этом начинают появляться ложные лаги, а глобальный прогноз остаётся неустойчивым. Следовательно, короткие окна не уничтожают возможность распознать память, но ухудшают интерпретируемость при сложной динамике.

Таким образом, детализация модели с запаздыванием образует зеркальный тест относительно базовой модели: там короткие окна в основном подтверждали роль X_n, здесь — роль Lag_1. Различие между двумя моделями сохраняется и на локальных фрагментах, однако в режиме сложной динамики эта локальная идентификация становится менее однозначной.

2.4 Описание смешанной модели и параметров эксперимента

В данном подразделе рассматривается смешанная модель

$$X_{n+1} = X_n + qX_n(K - X_n - \gamma X_{n-1}),$$

которая объединяет текущую реакцию и память в одном уравнении. Методологически это наиболее трудный случай главы: если базовая модель проверяла роль X_n, а запаздывающая — роль Lag_1, то здесь регрессия должна одновременно различать оба фактора, их относительный вес и знак лагового эффекта.

Стационарное состояние при $X_n = X_{n-1} = X^*$ имеет вид

$$X^* = \frac{1}{1+\gamma}.$$

Отсюда следует основной интерпретационный разрыв между режимами $\gamma > 0$ и $\gamma < 0$. При $\gamma > 0$ память усиливает ограничение и снижает

стационарный уровень. При $\gamma < 0$ память становится стимулирующей и повышает X^*; одновременно меняется знак лагового коэффициента в регрессии темпов прироста:

$$\omega_{n+1} \approx q - qX_n - q\gamma X_{n-1},$$

поэтому при $\gamma > 0$ коэффициент при Lag_1 отрицателен, а при $\gamma < 0$ — положителен.

2.4.1 Положительная память: структурная идентификация в устойчивом режиме

Репрезентативный режим $\gamma = 0.5$, $q = 1.5$ показывает, что в информативной устойчивой зоне смешанная модель хорошо читается регрессионно. STEPWISE и ENTER выделяют оба фактора, а отношение коэффициентов при X_n и Lag_1 согласуется с величиной памяти γ. Это важный результат: линейная регрессия различает уже не один доминирующий фактор, а двухфакторную структуру.

2.4.2 Отрицательная память: стимулирующий эффект предыстории

Репрезентативный режим $\gamma = -0.2$, $q = 1.5$ показывает качественно иной тип динамики. Стационарный уровень становится выше единицы,

$$X^* = \frac{1}{1+\gamma} = 1.25,$$

а коэффициент при Lag_1 меняет знак на положительный. Именно смена знака лагового эффекта выступает главным диагностическим признаком стимулирующей памяти. Тем самым смешанная модель даёт не только количественное, но и содержательное различение типов предыстории: память может либо усиливать ограничение, либо расширять потенциал развития.

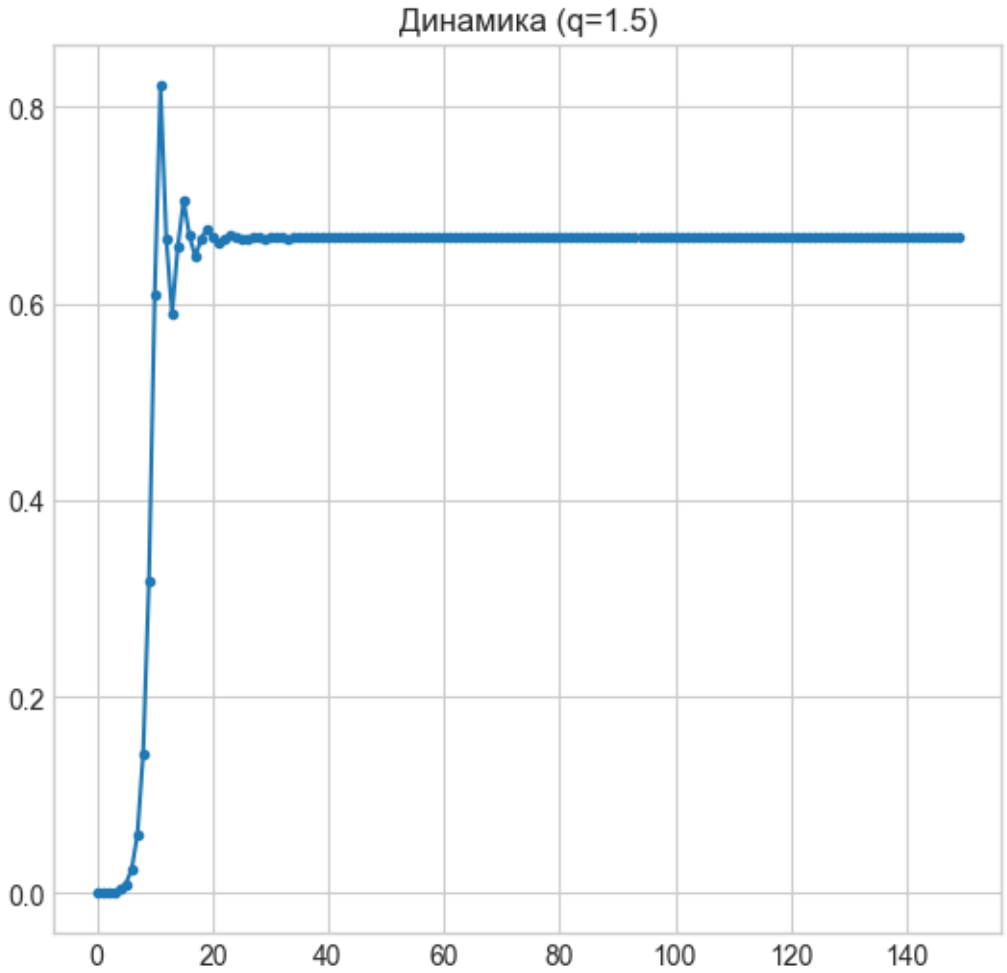

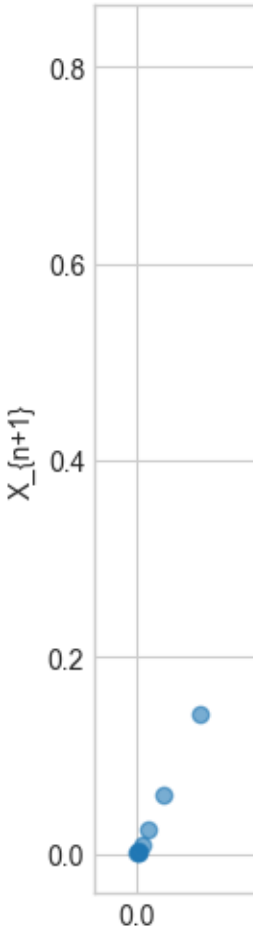

Рис. 2.3 – dyn_phas_15

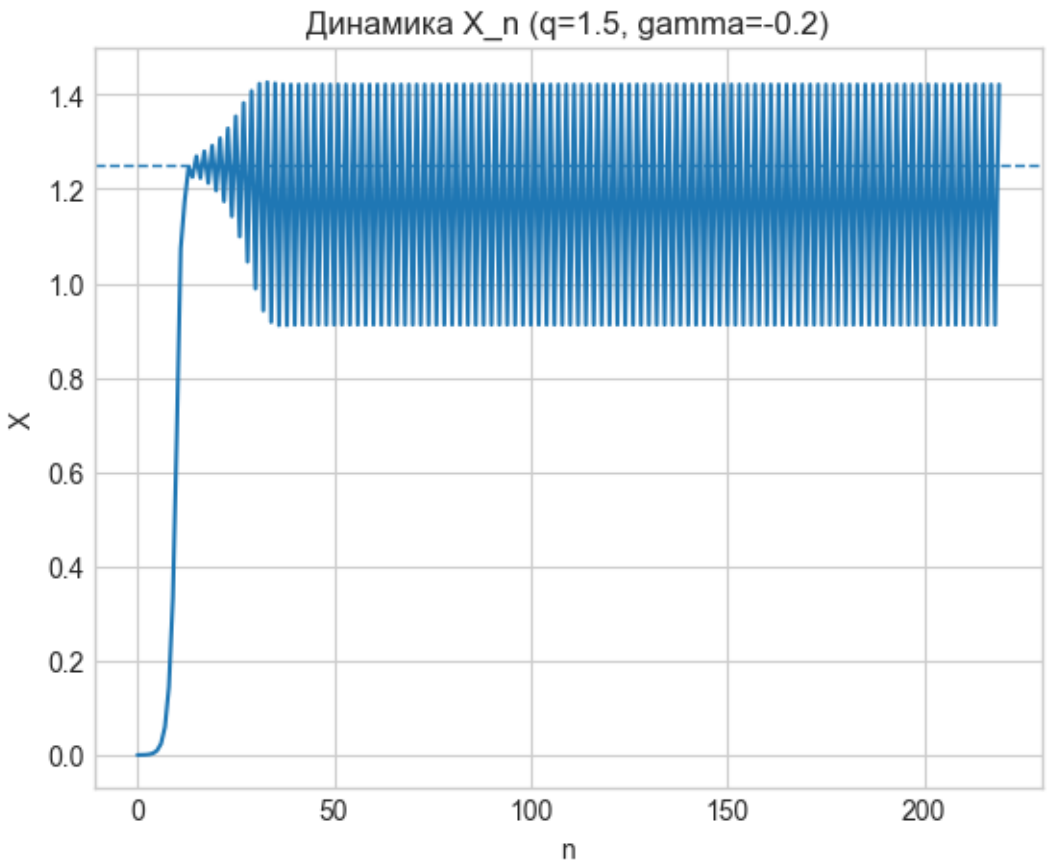

2.4.3 Зона деградации интерпретации

При росте интенсивности или при усилении памяти смешанная модель быстро входит в режимы, где формальная подгонка перестаёт быть содержательной. Для репрезентативного случая $\gamma = 0.5$, $q = 3.5$ траектория вырождается, фазовый портрет теряет регулярную структуру, а регрессионная идентификация становится неинформативной. Аналогичный эффект возникает и при достаточно сильной отрицательной памяти, когда стимулирующий вклад предыстории сочетается с сужением области устойчивости.

Особенно важно, что порог $\gamma = -1$ задаёт границу интерпретации стационарного состояния в принятой нормировке. При $\gamma < -1$ величина X^* становится отрицательной, и такие режимы следует трактовать как режимы, плохо интерпретируемые в данной нормировке, а не как обычные экономические траектории роста.

2.4.4 Итоговая таблица по смешанной модели

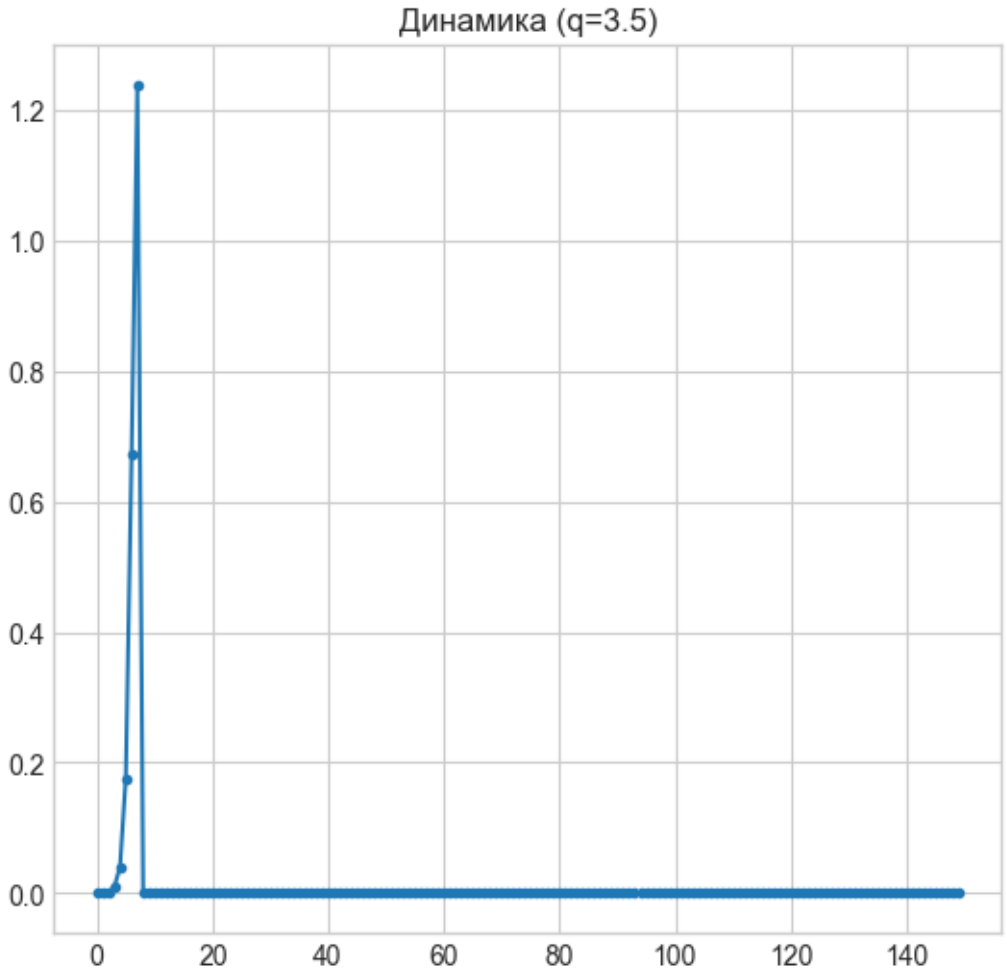

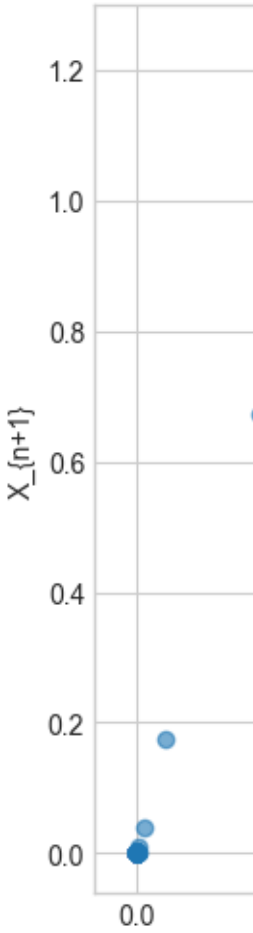

Рис. 2.4 – dyn_phas_35

Знак γ	Экономический смысл памяти	Знак коэффициента при Lag_1	Устойчивость	Тип сбоя интерпретации
$\gamma > 0$	память усиливает ограничение	отрицательный	область устойчивости сужается при росте q	при высокой интенсивности возникает вырождение траектории и теряется информативность прогноза
$\gamma < 0$, $-1 < \gamma < 0$	память расширяет потенциал развития	положительный	устойчивость становится более хрупкой	при усилении памяти и q возникает деградационный режим и срыв идентификации
$\gamma \leq -1$	режим плохо интерпретируем в данной нормировке	формально положительный, но содержательно нестабилен	стационарное состояние теряет осмысленность	регрессионные коэффициенты перестают иметь экономическую интерпретацию

2.4.5 Выводы по смешанной модели

Смешанная модель выступает кульминацией основной части главы. Во-первых, она показывает, что регрессия в принципе способна различать совместное действие текущего уровня и памяти. Во-вторых, знак γ меняет не только устойчивость системы, но и экономический смысл лагового эффекта. В-третьих, именно здесь наиболее ясно проявляется граница интерпретируемости: при усилении памяти и росте интенсивности формальная подгонка быстро теряет содержательную ценность, а траектория переходит в деградационный режим.

2.4.6 Дополнение: смешанная модель на коротких выборках (стадии + скользящие окна)

Короткие окна как тест двухфакторной структуры

Этот блок нужен как локальная проверка главного результата смешанной модели: сохраняется ли на коротких окнах одновременная идентификация X_n и Lag_1, и что разрушается первым при усложнении динамики.

Используются скользящие окна длины 25 и лаговое пространство до 10. В отличие от базовой и delay-модели здесь проверяется уже не один доминирующий фактор, а двухфакторная структура и знак лагового эффекта.

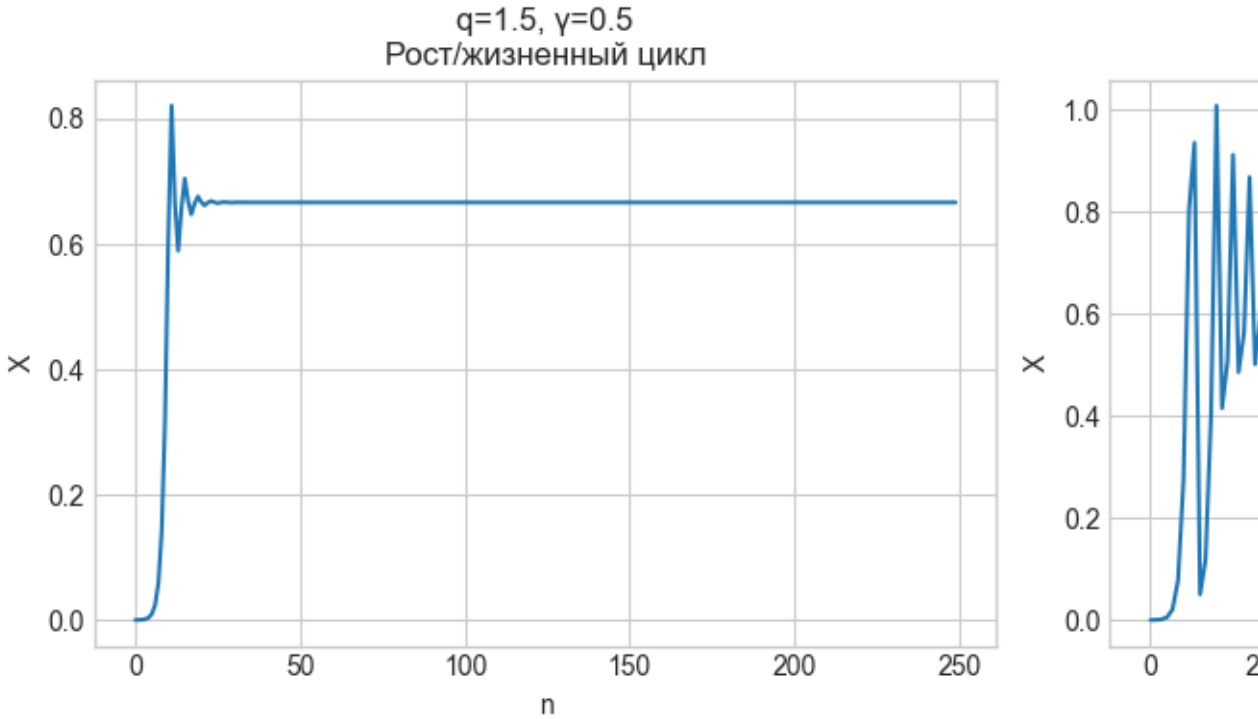

Тест 1. Сохраняется ли двухфакторная структура?

В устойчивом режиме при $\gamma > 0$ и умеренном q короткие окна в целом сохраняют правильную структуру: на информативных фрагментах коэффициенты при X_n и Lag_1 остаются близкими к теоретическим значениям $-q$ и $-q\gamma$. Это означает, что локальное окно в принципе не уничтожает возможность распознать смешанную природу процесса.

Однако уже в устойчивой зоне список переменных STEPWISE оказывается менее надёжным, чем в базовой и delay-модели: при выходе на плато лаги становятся взаимозаменяемыми, и память начинает распределяться по

нескольким предикторам. Поэтому для mixed-модели короткое окно следует читать прежде всего по ENTER, β и агрегированному лаговому эффекту, а не по буквальному списку выбранных лагов.

Тест 2. Что ломается при сложной динамике?

В циклическом и более сложном режимах короткие окна ещё могут локально удерживать ядро структуры $X_n + Lag_1$, но интерпретируемость падает быстрее, чем в предыдущих моделях. Ложные лаги появляются раньше, а STEPWISE начинает смешивать физические предикторы с локальными статистическими дублёрами. При дальнейшем усложнении режима окно быстро становится вырожденным: коэффициенты теряют устойчивость, а сама процедура отбора может перестать возвращать модель.

Именно здесь наиболее ясно проявляется главный риск mixed-модели на коротких окнах: первой разрушается не формальная подгонка, а интерпретируемость лаговой структуры.

Тест 3. Видна ли на окнах смена знака памяти?

В устойчивом режиме при $\gamma < 0$ короткие окна по-прежнему позволяют распознать двухфакторную структуру, но теперь лаговый эффект меняет знак. Это наиболее важный локальный результат для стимулирующей памяти: окно фиксирует не только присутствие памяти, но и изменение её экономического смысла.

При усилении отрицательной памяти устойчивость окна быстро падает. Число информативных фрагментов сокращается, а регрессионные оценки становятся нестабильными. Следовательно, mixed-модель подтверждает общий вывод главы: короткие окна не уничтожают возможность локальной идентификации, но резко ухудшают интерпретируемость при усложнении динамики.

Тест	Истинная структура	Что видно на окнах	Что разрушается первым	Как интерпретировать
Устойчивый режим, $\gamma > 0$	$X_n + Lag_1$	оба фактора читаются	список лагов STEPWISE	опираться на ENTER, β, B_Σ

Тест	Истинная структура	Что видно на окнах	Что разрушается первым	Как интерпретировать
Сложная динамика, $\gamma > 0$	$X_n + Lag_1$	ядро частично сохраняется	интерпретируемость лаговой структуры	считать ложные лаги признаком ухудшения окна
Устойчивый режим, $\gamma < 0$	$X_n + Lag_1$, $B(Lag_1) > 0$	сохраняется двухфакторность и виден знак памяти	устойчивость окна при усилении памяти	использовать знак лагового коэффициента как диагностический признак

Таким образом, short-window детализация mixed-модели завершает линию сравнения трёх семейств. В базовой модели окно главным образом подтверждает роль X_n, в delay-модели — роль Lag_1, а в mixed-модели оно способно удерживать двухфакторную структуру только в информативных режимах. При усложнении динамики именно mixed-модель быстрее всего переходит от идентификации к проблеме интерпретируемости.

2.4.7 Введение к серии дополнительных экспериментов 2.4.1-2.4.3

Серия дополнительных экспериментов была нужна для того, чтобы уточнить границы применимости короткого окна. После основного анализа стало ясно, что высокая подгонка сама по себе ещё не гарантирует корректную структурную интерпретацию, а ложные лаги, дрейф коэффициентов и вырождение окна могут иметь различную природу. Поэтому в бакалаврской версии работы из всей исследовательской программы оставлены только три укрупнённых результата: сопоставление direct и regression, диагностика режима и интерпретируемости окна, а также сравнение основных контуров анализа с краткими проверками устойчивости.

Подробные parameter sweeps, расширенные таблицы метрик и полные серии однотипных графиков по дополнительным экспериментам вынесены в приложения.

2.4.8 Сопоставление прямой идентификации параметров отображения и структурной регрессии

Первый эксперимент отвечал на вопрос, можно ли заменить регрессионный контур прямой локальной идентификацией параметров отображения. Для базовой модели параметры восстанавливались по минимальному блоку из трёх точек, для модели с запаздыванием — по четырём точкам, для смешанной модели — по короткому блоку с локальным решением системы для X_n и X_{n-1}. В качестве сопоставимого контура использовалась структурная регрессия по теоретически правильным регрессорам на окне длины 25.

Проверка гипотезы в рамках вычислительного эксперимента показала, что на чистых траекториях direct-подход действительно может выступать локальным structural probe. Для базовой и delay-модели он воспроизводит структуру закона в пределах вычислительной точности, а для mixed-модели иногда лучше улавливает геометрию редких информативных фрагментов. Однако даже слабый шум быстро делает его менее устойчивым, чем регрессия. На рисунке ниже это видно по росту ошибки главного параметра в зависимости от уровня шума.

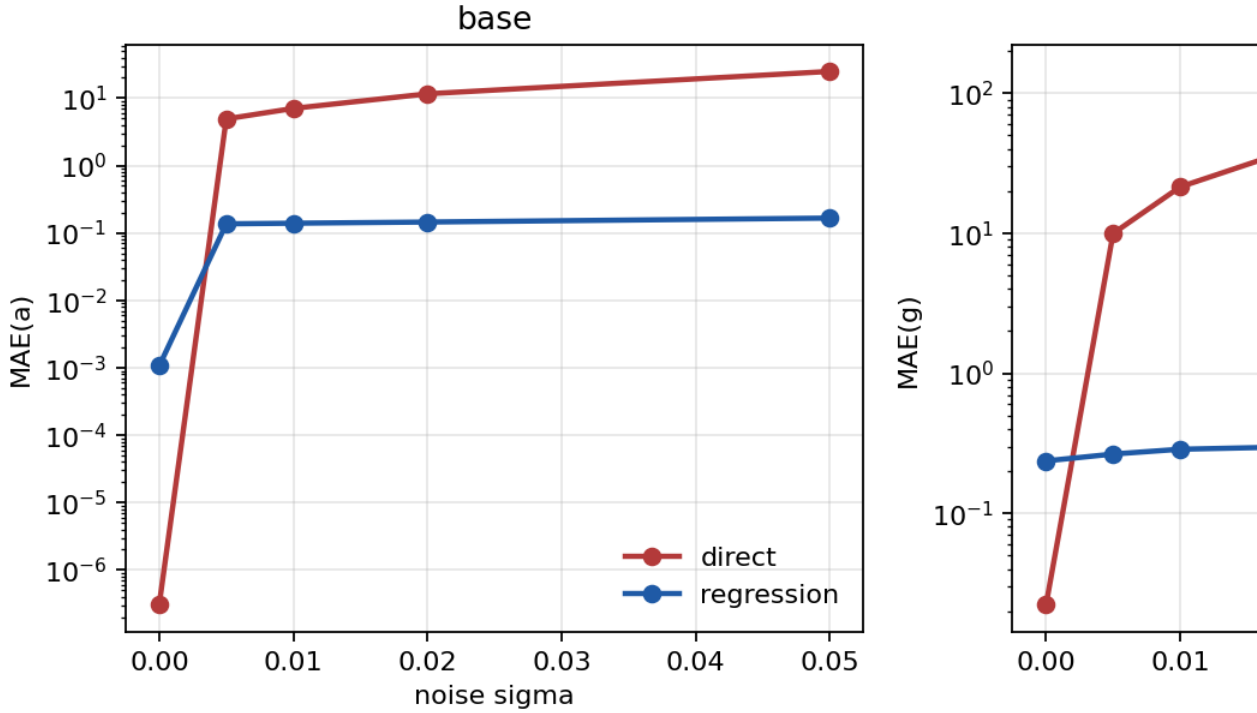

Главный вывод здесь состоит в том, что прямая идентификация полезна не как замена regression, а как локальный диагностический контур. Она помогает проверить форму закона и момент вырождения окна, но не обеспечивает

устойчивого чтения параметров на шумных данных.

2.4.9 Диагностика режима и границы интерпретируемости короткого окна

Второй укрупнённый результат связан с вопросом, когда короткое окно вообще допускает содержательное чтение. Здесь были сведены вместе режимная диагностика, эксперименты по длине окна, сравнению B- и β-коэффициенто а также проверки локальной дисперсии и кондиционности лагового пространства.

Прежде всего оказалось, что выбор инструмента нельзя начинать с регрессии как таковой. Сначала требуется определить тип режима: монотонный, циклический, переходный или вырожденный. Только после этого имеет смысл проверять само окно на интерпретируемость. Показано, что длина окна действительно важна, но не решает проблему автоматически. Более длинное окно уменьшает влияние случайной геометрии и снижает долю ложных лагов, однако не устраняет содержательную мультиколлинеарность. В проблемных окнах ранжирование по $|\beta|$ обычно устойчивее, чем по $|B|$, поскольку стандартизация частично компенсирует различие масштабов. Вместе с тем и этот выигрыш работает только там, где окно сохраняет ненулевую локальную дисперсию сигнала.

Фактор	Основной вывод	Практический смысл
Режим окна	тип динамики должен быть определён до выбора регрессии	сначала классифицируется режим, затем выбирается контур чтения
Длина окна	Более длинное окно снижает долю артефактов, но не гарантирует правильную структуру	окно нужно увеличивать осмысленно, а не механически
$\|\beta\|$ против $\|B\|$	β полезнее в проблемных окнах	ранжирование факторов лучше вести по стандартизованным коэффициентам
Локальная дисперсия	Падение $Var(\omega)$ лишает окно структурного сигнала	такие окна не следует читать как память

Кондиционность	Высокая $\kappa(\widetilde{X})$ усиливает ложные лаги	перед чтением лагов нужна геометрическая проверка

Тем самым короткое окно может оказаться неинтерпретируемым по двум разным причинам: либо из него исчезает локальный сигнал, либо лаговое пространство становится практически взаимозаменяемым. В первом случае речь идёт о low-dispersion окнах, во втором — о collinearity-heavy окнах. Именно поэтому высокий fit не тождествен интерпретируемости, а режимная диагностика должна предшествовать регрессионному чтению.

2.4.10 Сравнение основных контуров анализа и проверки устойчивости

Третий укрупнённый результат относится уже к выбору инструмента внутри допущенного окна. Для этого были сопоставлены ENTER и STEPWISE, агрегированный показатель памяти B_{Σ}, а также краткие контрольные проверки устойчивости через Lasso, Ridge, Elastic Net, PCA и настройку p-порога.

Здесь был получен простой и важный результат. Lasso лучше очищает простую разреженную структуру, STEPWISE чаще удерживает конкурирующие содержательные факторы в mixed-режимах, ENTER и Ridge полезны как плотные референсные модели, а PCA и настройка p-порога выступают лишь как контрольные проверки устойчивости. Иными словами, ни один из этих методов не заменяет предварительную режимную диагностику и фильтр интерпретируемости, а лишь уточняет чтение уже допущенного окна.

Контур	Сильная сторона	Ограничение
STEPWISE	сохраняет competing true factors	чувствителен к ложным включениям
Lasso	очищает простую структуру	может терять часть истинной памяти
ENTER / Ridge	дают плотный референс	плохо подходят для окончательной интерпретации
PCA	диагностирует численную вырожденность	не даёт содержательной замены исходным лагам
p-tuning	настраивает жёсткость отбора	не устраняет геометрию ложных лагов

Таким образом, Lasso, PCA и настройка p-value не образуют самостоятельных методологических направлений. Их роль состоит в проверке устойчивости главного вывода: никакая локальная статистическая настройка не заменяет режимную диагностику и фильтр интерпретируемости окна.

2.4.11 Итоговая схема интерпретации результатов

По итогам дополнительных экспериментов маршрут анализа короткого окна можно записать в виде четырёх шагов.

1. Сначала определяется режим процесса и решается вопрос, уместен ли регрессионный контур.
2. Затем проверяются локальная дисперсия сигнала и геометрия лагового пространства.
3. После этого выбирается контур чтения: direct-probe, структурная регрессия, агрегированный показатель памяти или отказ от интерпретации.
4. Только на последнем этапе интерпретируются коэффициенты, их знаки и относительная значимость факторов.

Главный результат серии 2.4.1-2.4.3 состоит в переходе от универсальной эконометрической интерпретации к режимно-зависимой процедуре анализа. В нелинейной динамике качество подгонки, численная устойчивость и физическая интерпретируемость не совпадают и потому должны оцениваться раздельно.

2.5 ЗАКЛЮЧЕНИЕ И ОБЩИЕ ВЫВОДЫ ПО РЕЗУЛЬТАТАМ МОДЕЛИРОВАНИЯ

2.5.1 Общий вывод главы

В рамках проведённого вычислительного эксперимента получены пять основных выводов.

1. Линейная регрессия способна надёжно восстанавливать структурную форму темпа прироста на длинных траекториях и в информативных режимах короткого окна.
2. Ложные лаги появляются прежде всего в циклических, переходных и геометрически вырожденных окнах, а не только как дефект конкретно-

го алгоритма отбора.

3. Высокий fit не равен хорошей интерпретации: окно может хорошо подгоняться и одновременно не допускать содержательного чтения коэффициентов.
4. Короткие окна полезны как инструмент локальной диагностики, но требуют предварительной проверки режима, локальной дисперсии и кондиционности лагового пространства.
5. Главный результат synthetic-части состоит в построении маршрута анализа, который затем переносится на реальные данные: сначала режим, затем интерпретируемость, затем выбор контура и только после этого чтение коэффициентов.

Таким образом, глава 2 показывает не “лучшую регрессию вообще”, а условия, при которых регрессионный анализ в нелинейной динамике остаётся содержательно допустимым.

2.5.2 Ограничения главы 2

Полученные результаты следует интерпретировать с учётом ограничений проведённого исследования.

1. Эксперименты проводились на synthetic-данных, где закон генерации задавался заранее и потому исследование велось в контролируемых условиях.
2. Рассматривался ограниченный набор дискретных нелинейных моделей: базовая, запаздывающая и смешанная.
3. В части экспериментов использовались чистые траектории или простые схемы шума, что не исчерпывает разнообразия реальных возмущений.
4. Результаты зависят от длины окна, выбранного лагового пространства и конкретной конфигурации режимов, поэтому их следует переносить на эмпирику как методологический маршрут, а не как готовый набор универсальных численных порогов.

Эти ограничения не отменяют полученных выводов, но задают корректные границы их применения и непосредственно подводят к главе 3, где построенный маршрут проверяется уже на реальных данных.

3 ПЕРЕНОС РЕЖИМНО-ЗАВИСИМОГО АППАРАТА НА РЕАЛЬНЫЕ ДАННЫЕ

3.1 Источники данных, ограничения и гипотезы эмпирической части

Эмпирическая часть работы опирается на два корпуса данных.

3.1.1 Корпус 1: индексы промышленного производства

Файл “февраль 2026 OKVED.XLS” содержит 47 месячных рядов за период 2013-01 — 2025-12, причём каждый ряд представлен в трёх версиях: скорректированной и сглаженной, скорректированной без сглаживания и сырой. Таблицы индексов промышленного производства подготовлены Владимиром Аркадьевичем Бессоновым и переданы автору через Ю.А. Полунина. В настоящей главе этот корпус используется как предварительная проверка переносимости метода, а не как основной объект эмпирического анализа.

3.1.2 Корпус 2: выручка стабильных компаний

Файл “Данные по выручке 2003-2022.xlsx” содержит 23943 стабильные компании и годовой горизонт 2003–2022. Основной смысл этого корпуса связан не с отдельными фирмами как панелью, а с медианными траекториями групп и отраслей. Именно этот корпус является центральным для эмпирической части главы, поскольку он ближе к логике работ Ю.А. Полунина и лучше соответствует теме социально-экономических процессов.

3.1.3 Почему корпуса нельзя напрямую объединять

Индексы промышленного производства и выручка различаются по экономической природе, частоте наблюдений и отраслевой кодировке. Поэтому в основной части главы они не сравниваются как единый массив. Индексы используются только как внешняя проверка переносимости режима анали-

за, тогда как содержательный эмпирический результат строится на выручке компаний.

3.1.4 Ограничения данных

Эмпирическая часть имеет четыре принципиальных ограничения.

1. На реальных данных невозможно точное восстановление истинной модели: исследование может опираться только на устойчивость результатов, повторяемость режимов и допустимость интерпретации.
2. Выручка и промышленные индексы имеют разную природу: сравнивать их уровни напрямую методологически неверно.
3. Около 22.2% наблюдений по выручке не имеют отраслевого кода, поэтому отраслевой анализ требует предварительной фильтрации.
4. В работе сравниваются не уровни рядов, а режимы, интерпретируемость окна и допустимость выбранного контура чтения.

3.1.5 Гипотезы эмпирической части

В эмпирической части проверяются следующие гипотезы.

1. Режимно-зависимый подход, построенный на синтетических данных, переносим на реальные данные по выручке как процедура выбора допустимого контура анализа.
2. Полные интервалы по выручке чаще дают высокий fit, но реже допускают содержательное чтение, чем короткие окна.
3. Группы и отрасли по выручке различаются не только формой траектории, но и типом допустимой интерпретации.
4. Промышленные индексы могут использоваться как внешняя проверка переносимости метода, но не как второй равноправный центр главы.

3.2 Дизайн эмпирической части

В бакалаврской версии работы эмпирическая глава организована вокруг одного основного вопроса: переносится ли режимно-зависимый подход из синтетической части на реальные данные по выручке.

Для ответа на этот вопрос использовались три последовательных шага.

1. Сначала на промышленном корпусе выполнялась краткая внешняя проверка переносимости построенного маршрута анализа.
2. Затем на выручке компаний исследовались медианные траектории трёх групп фирм, различающихся по темпам роста.
3. После этого анализ переносился на отраслевой подкорпус выручки, где проверялась читаемость коротких окон уже на уровне секторов.

Таким образом, в основной текст вынесена прежде всего денежная линия исследования, тогда как промышленный корпус выполняет роль предварительной проверки устойчивости метода вне синтетической среды.

3.3 Предварительная проверка переносимости на промышленных индексах

3.3.1 Вопрос, данные и главный результат

Вопрос этого шага состоял в том, сохраняется ли построенный в главе 2 маршрут анализа на реальных месячных рядах. Для этого сравнивались три версии одного и того же промышленного процесса: скорректированная и сглаженная, скорректированная без сглаживания и сырая.

Главный результат оказался достаточно простым. В качестве рабочего слоя наблюдения был выбран скорректированный, но не сглаженный ряд adj_unsmoothed. Сглаженный ряд создавал избыточную упорядоченность, а сырой — избыточную турбулентность. На этом слое было показано, что короткое окно и на реальных данных не должно читаться автоматически: сначала определяется режим, затем проверяется интерпретируемость, и только после этого допускается регрессионный контур.

3.3.2 Ограничение этого шага

Промышленный корпус не является центральным эмпирическим результатом главы. Его функция ограничена предварительной проверкой переносимости метода. Подробные отраслевые карточки и промежуточные карты в основной текст не включаются, поскольку содержательный центр эмпирической части расположен в анализе выручки.

Расширенные карточки отраслей и полные сводки по промышленному корпусу приведены в приложениях.

3.4 Группы компаний по выручке

3.4.1 Вопрос и данные

Основной эмпирический вопрос главы формулируется так: переносится ли режимно-зависимый подход на реальные годовые траектории выручки. Для ответа на него компании были разделены на три группы по темпам роста 2010–2014: группу высоких темпов роста, группу низких темпов роста и группу средних темпов роста. В каждой группе оказалось по 2394 фирмы.

3.4.2 Режимное чтение

На полных интервалах 2014–2019 и 2014–2022 было показано, что высокий fit ещё не означает содержательной читаемости. Большинство полных интервалов у групп выручки относится к низкодисперсионным окнам, где регрессия формально может выглядеть устойчивой, но не даёт надёжной структурной интерпретации. Короткие окна длины 5 и 7 лет оказываются информативнее: именно на них различаются допустимые режимы чтения для групп высоких, низких и средних темпов роста.

Чтобы не сохранять служебные метки без пояснения, в дальнейшем используются следующие русские формулировки. Если окно допускает структурное чтение, это означает, что регрессия может быть интерпретирована содержательно. Если окно не допускает содержательной интерпретации, это означает, что коэффициенты не должны использоваться как аргумент о памяти или устойчивом законе движения. Если окно требует фазового чтения, то допустимо говорить только о форме траектории и переломах, но не о надёжной лаговой структуре.

3.4.3 Главный результат

Главный результат B1 состоит в том, что группы фирм различаются не только уровнем и направлением роста, но и типом допустимого анализа. Группа высоких темпов роста чаще открывается для интерпретации на коротких окнах, группа низких темпов роста чаще остаётся закрытой для содержательного регрессионного чтения, а группа средних темпов роста занимает промежуточное положение. Следовательно, режимно-зависимый под-

ход переносится на реальные годовые ряды выручки и позволяет различать не только траектории, но и саму возможность их анализа.

График медианных траекторий показывает, что различие между тремя группами выражается не в одном агрегированном коэффициенте, а в форме самих траекторий.

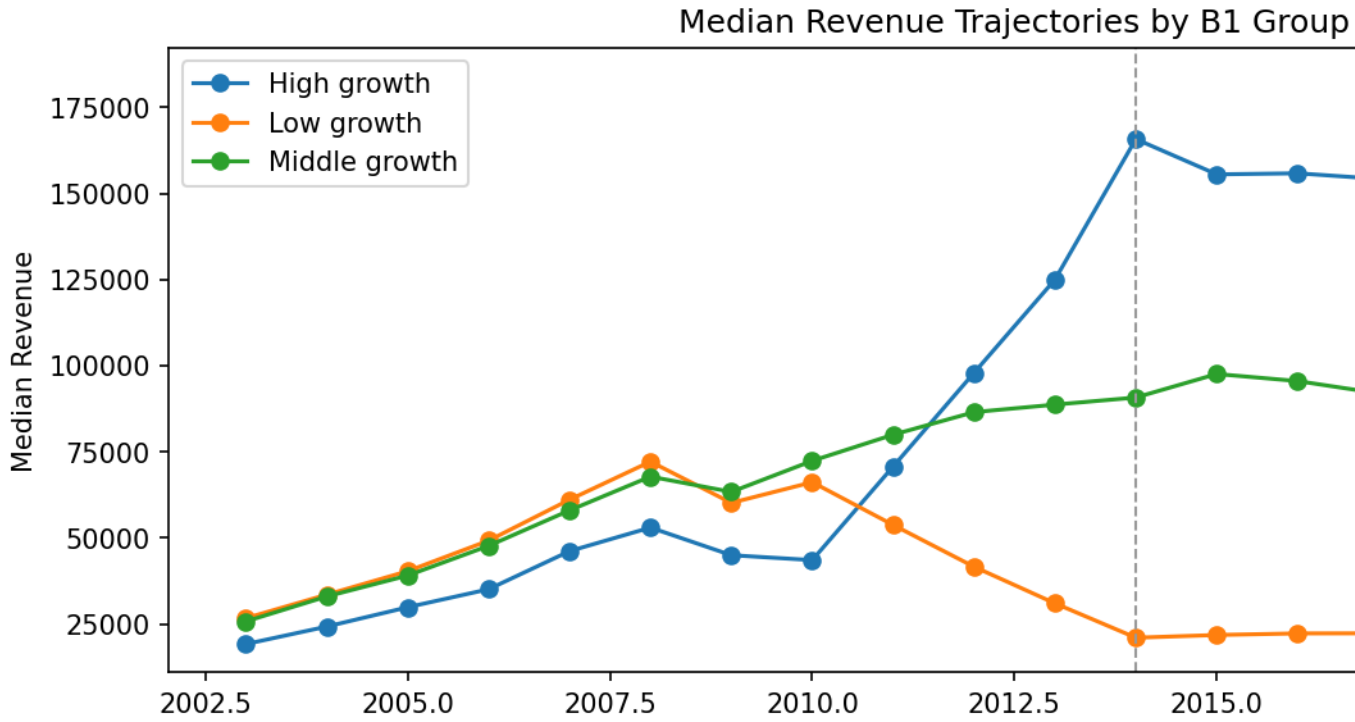

Рис. 3.1 – B1: Group Trajectories

Второй рисунок нужен для другого вывода: он показывает, что группы различаются именно по доле окон, допускающих содержательное short-window чтение.

3.4.4 Ограничение

Этот результат относится к группам фирм, агрегированным по прошлому темпу роста. Поэтому он не описывает ещё отраслевые различия и не даёт оснований переносить выводы на всю денежную реальность без дополнительной проверки по секторам.

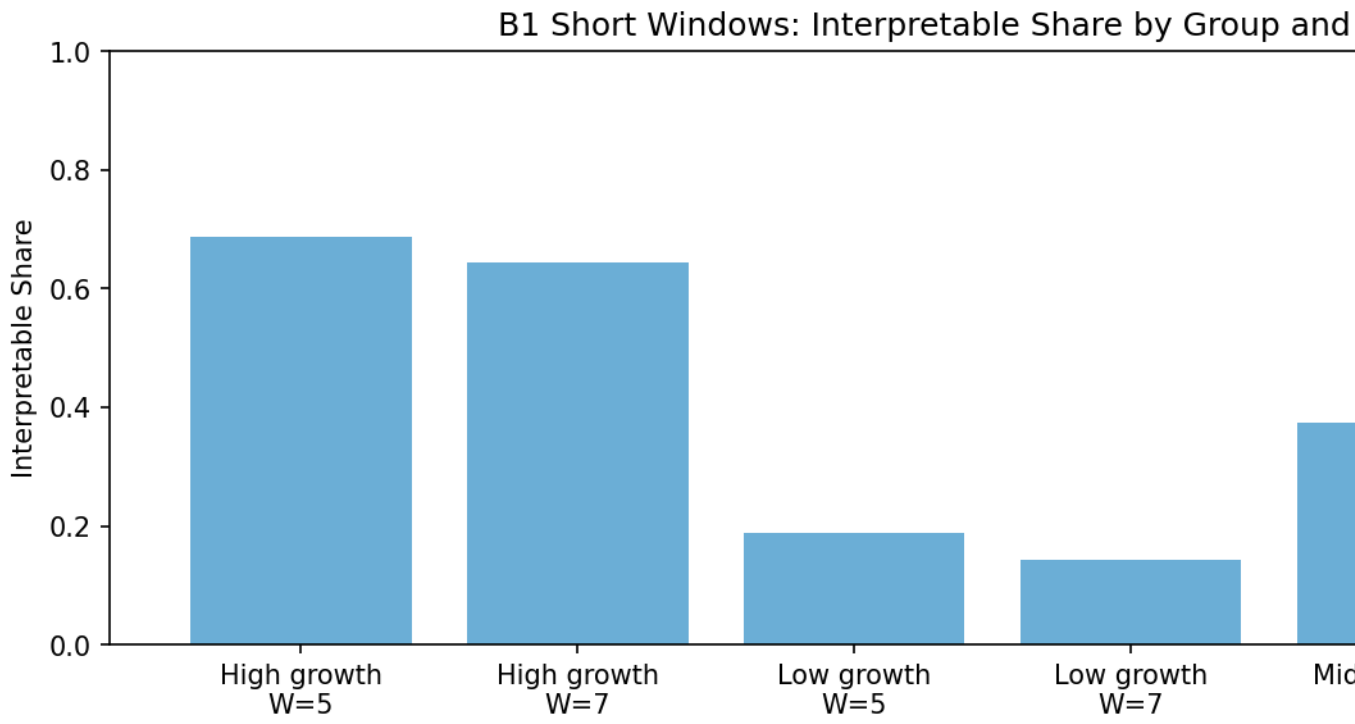

Рис. 3.2 – B1: Short-Window Interpretable Share

3.5 Отраслевой подкорпус выручки

3.5.1 Формирование корпуса

Если B1 работал с группами фирм по темпам роста, то B2 переводит линию выручки на отраслевой уровень. Единицей анализа становится двухзначный сектор старого ОКВЭД.

В B2 использовался жёсткий фильтр:

- заполненный и нормализуемый код;
- устойчивое присутствие в годовой панели;
- не менее 100 фирм в секторе.

После фильтра получен основной отраслевой слой:

total firms	firms with OKVED	included firms	included sectors
23943	18628	17497	29

Линия выручки здесь упирается не только в моделирование, но и в качество кодировки. Полученный компромисс позволил сохранить и масштаб, и интерпретируемость, а значит, сделал B2 полноценной отраслевой линией, а не приложением к B1.

3.5.2 Полные интервалы и короткие окна

На полном интервале B2 оказался менее закрытым, чем B1:

Интервал	структурное чтение	фазовое чтение	агрегированный регрессионный контур	окно не допускает содержательной интерпретации
2014-2019	15	1	2	11
2014-2022	20	4	1	4

Содержательный смысл этого результата состоит в различии двух типов агрегации: группы фирм по прошлому темпу роста смешивают разные механизмы внутри общего роста, тогда как отрасли чаще объединяют фирмы с более близкой экономической логикой. Поэтому отраслевой денежный слой оказался более читаемым на полном интервале.

Именно на коротких окнах 5 и 7 B2 превратился в полноценную отраслевую карту читаемости. При W = 7 наиболее читаемыми оказались:

- 28, 36, 63 с interpretable_share = 0.9286;
- 26, 60, 72, 29, 31, 24, 21 с interpretable_share = 0.8571.

Наиболее закрытыми оказались:

- 52 с interpretable_share = 0.0000;
- 70, 41, 93 и некоторые другие сектора, где окно чаще не допускает содержательной интерпретации.

Следовательно, B2 дал уже не broad-group analysis, а именно отраслевую карту читаемости выручки.

Первый рисунок важно понимать не как витрину лучших R^2. Его задача состоит только в демонстрации неоднородности полного интервала: даже высокий fit сам по себе не означает структурной читаемости.

Второй рисунок является центральной иллюстрацией всего B2, поскольку именно он показывает различия между секторами по допустимости short-window чтения.

Именно B2 переводит денежную линию из первичной эмпирической проверки в самостоятельный прикладной корпус. Здесь линия выручки впервые становится не просто подтверждением переносимости метода, а самостоятельной отраслевой картой допустимого и недопустимого short-window

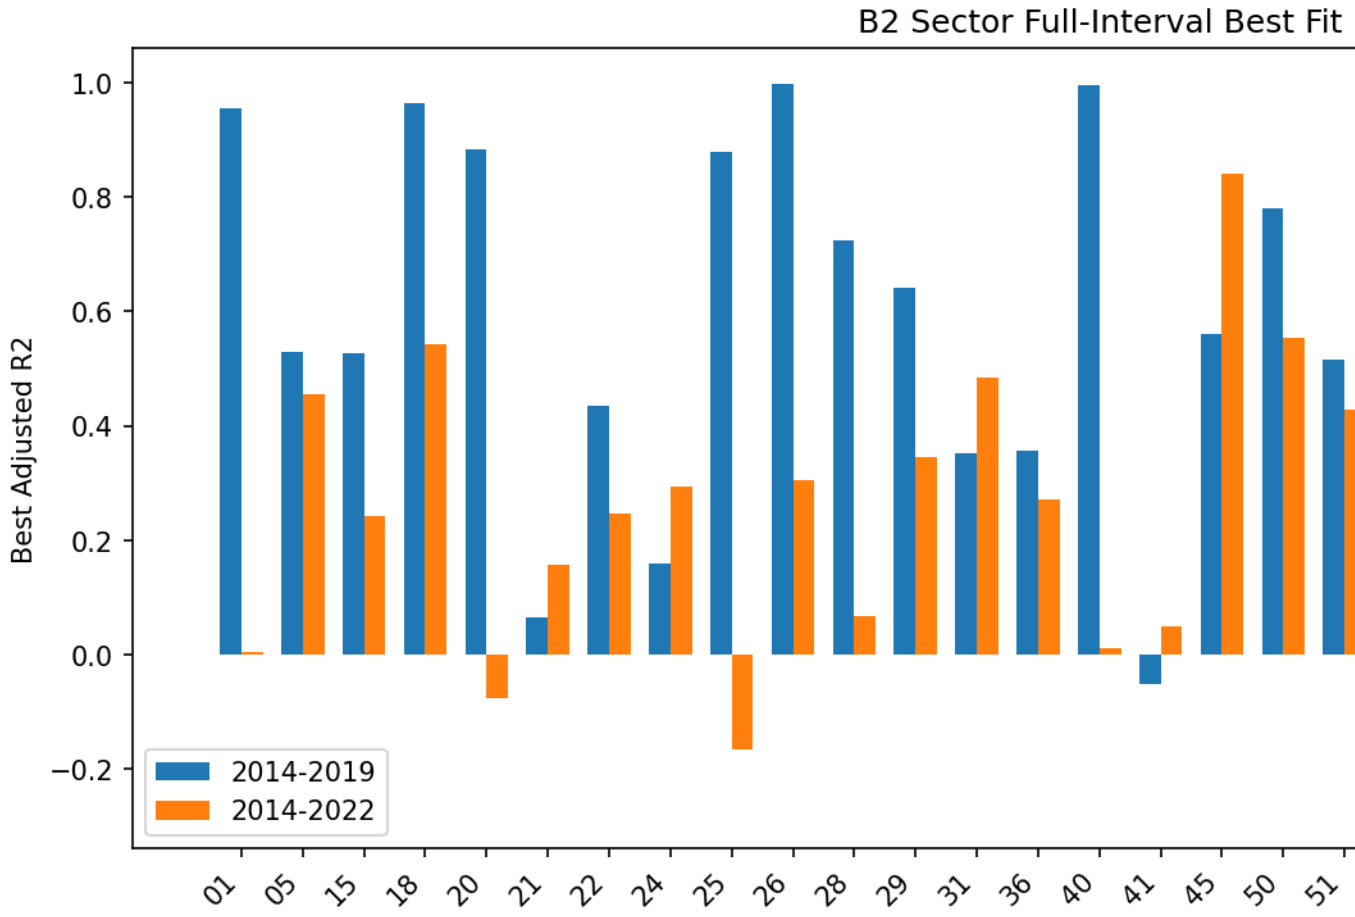

Рис. 3.3 – B2: Sector Full-Interval Best Fit

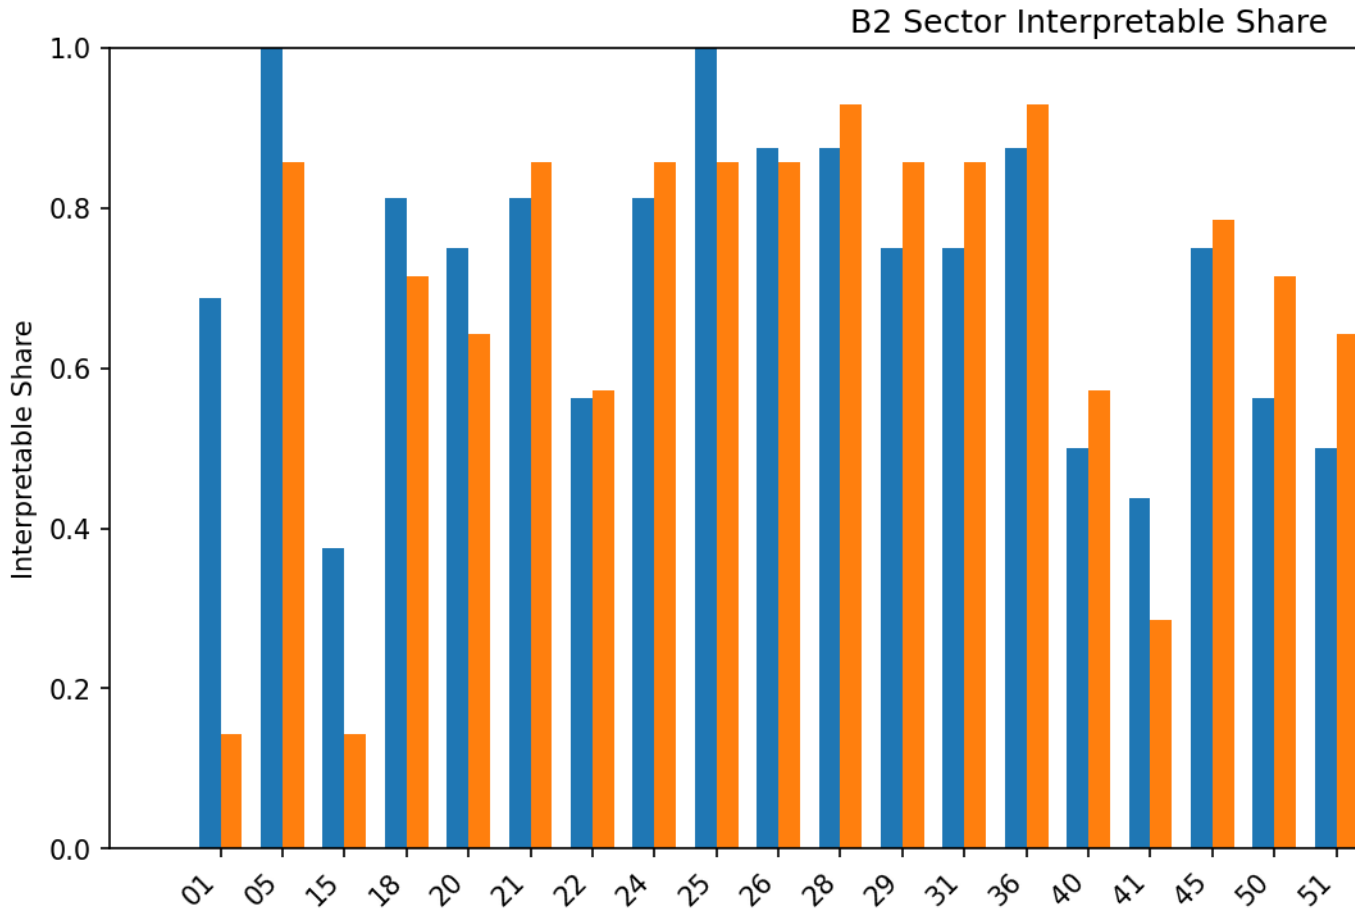

Рис. 3.4 – B2: Sector Interpretable Share

чтения.

3.5.3 Шоки 2020 и 2022

По отраслевой выручке уже проявились содержательные before/after patterns:

- 20: сильный восстановительный отклик после 2020;
- 22: падение перед шоком и восстановление после;
- 24: положительный вход в 2020 и ещё более сильный выход;
- 26, 28, 29: выраженный восстановительный паттерн после 2020;
- 40: шок заметен, но по амплитуде слабее.

Следовательно, B2 состоялся как отраслевая карта читаемости выручки. Даже внутри одной годовой денежной реальности разные отрасли различаются по допустимому контуру чтения.

3.6 Общие выводы по главе реальных данных и практическая значимость

Итоги эмпирической части можно свести к следующей таблице.

Корпус	Что удалось интерпретировать	Что не удалось интерпретировать	Почему	Практический вывод
Промышленные индексы	переносимость режима анализа и выбор рабочего слоя наблюдения	устойчивую структурную интерпретацию всех отраслевых окон	часть окон вырождается или зависит от способа сглаживания	промышленный корпус пригоден как внешняя проверка метода
Группы компаний по выручке	различие между группами высоких, низких и средних темпов роста по допустимому контуру чтения	полные интервалы как готовую лаговую структуру	высокий fit часто сочетается с низкой локальной информативностью	анализ групп следует вести через короткие окна

Корпус	Что удалось интерпретировать	Что не удалось интерпретировать	Почему	Практический вывод
Отраслевой подкорпус выручки	карту отраслевой читаемости и шоковые паттерны 2020/2022	единый способ чтения для всех секторов	отрасли различаются по режиму и интерпретируемости окна	сектора нужно заранее разделять по допустимому аналитическому контуру

3.6.1 Основные выводы главы

В рамках проведённого исследования получены три основных результата.

1. Перед запуском регрессии необходимо отбраковывать окна, не допускающие содержательной интерпретации.
2. Различение режима должно предшествовать выбору аналитического контура.
3. Работа с выручкой групп и отраслей требует коротких окон и предварительной проверки допустимости чтения, а не прямого использования полного интервала.

Именно в этом состоит главный итог главы: реальные данные по выручке допускают содержательный анализ только после предварительной процедуры отбора и интерпретации окна.

3.6.2 Практическая значимость

Практическая ценность полученного результата состоит в трёх типовых применениях.

1. Отбраковка неинтерпретируемых окон снижает риск ложных выводов по данным, где высокий fit создаёт лишь видимость устойчивой структуры.
2. Предварительное различение режимов позволяет выбирать метод анализа до запуска регрессии, а не после получения случайного набора коэффициентов.
3. Более аккуратная работа с выручкой групп и отраслей делает возмож-

ным содержательное сравнение траекторий без подмены интерпретации простым ранжированием по R^2.

Такой подход может быть полезен исследователю, отраслевому аналитику, макроаналитику и корпоративному аналитику в тех задачах, где приходится работать с короткими и режимно неоднородными рядами.

3.6.3 Ограничения и итоговый вывод

Полученные результаты не следует трактовать как универсальную прогностическую схему или как основание для прямого сравнения любых экономических рядов. В настоящей главе исследовалась прежде всего допустимость содержательного чтения короткого окна на реальных данных по выручке. Поэтому корректнее говорить не о единой модели для всех рядов, а о процедуре анализа, которая позволяет сначала определить режим, затем проверить интерпретируемость окна и только после этого переходить к коэффициентам и локальной структуре.

Итоговый вывод главы 3 состоит в следующем: режимно-зависимый подход, построенный в синтетической части, переносится на реальные данные по выручке как процедура отбора и допустимой интерпретации коротких окон. Его практический смысл состоит не в максимизации fit, а в снижении риска ошибочного чтения групповых и отраслевых денежных траекторий.

A Приложение A. Дополнительные synthetic-эксперименты и проверки устойчивости

В основное тело диплома включены только те synthetic-результаты, которые непосредственно поддерживают центральный тезис работы. Остальные материалы вынесены в приложение.

В приложение A входят:

1. Полные серии однотипных графиков по базовой, запаздывающей и смешанной моделям, включая дополнительные режимы, фазовые портреты и прогнозные продолжения.
2. Резервные parameter sweeps и дополнительные сценарии по параметрам q и γ смешанной модели.
3. Развёрнутые robustness checks по длине окна, сравнению B и β, критерию интерпретируемости, регуляризации, PCA и настройке p-порога.
4. Полные таблицы метрик по методам, окнам и режимам, которые были использованы при сжатии раздела 2.4 до основной бакалаврской версии.

Электронные материалы приложения A соответствуют следующим наборам файлов:

- outputs/planA — direct vs regression, шумовой sweep и диагностическая полезность;
- outputs/planB — влияние длины окна и отношение W/T;
- outputs/planC — сравнение коэффициентов B и β;
- outputs/planD — ENTER, STEPWISE и регуляризованные методы;
- outputs/planE — чувствительность к p-порогу;
- outputs/planF — PCA и ортогонализация лагового пространства;
- outputs/planG — режимная предклассификация и выбор контура;
- outputs/planH — дисперсия, кондиционность и риск вырождения окна.

В Приложение Б. Расширенная линия промышленных индексов

В основной текст глава 3 включает только краткую внешнюю проверку переносимости метода на промышленных индексах. Развёрнутые результаты по IPP вынесены в приложение Б.

В приложение Б входят:

1. Подробные сравнения трёх слоёв наблюдения (adj_smoothed, adj_unsmoothed, raw).
2. Полные таблицы режимов и интерпретируемости для всех окон по промышленному корпусу.
3. Отраслевые карточки, case overview и дополнительные графики по шокам 2020 и 2022.
4. Расширенные таблицы устойчивости маршрута анализа по промышленным рядам.

Электронные материалы приложения Б соответствуют следующим наборам файлов:

- outputs/real_data/ipp_routing_all_variants — режимы, интерпретируемость и выбор рабочего слоя наблюдения;
- outputs/real_data/ipp_case_cards — расширенные отраслевые карточки, case overview и шоковые сводки.

C Приложение B. Дополнительные таблицы по линии выручки

Основной текст включает только те результаты по выручке, которые необходимы для доказательства центрального тезиса. Расширенные таблицы и дополнительные графики по группам и отраслям вынесены в приложение B.

В приложение B входят:

1. Полные таблицы состава групп фирм по темпам роста и соответствующие годовые медианные траектории.
2. Развёрнутые interval- и window-summary таблицы по группам выручки.
3. Полные секторные таблицы по отраслевому подкорпусу выручки, включая покрытия, устойчивость и шоковые профили.

Электронные материалы приложения B соответствуют следующим наборам файлов:

- outputs/real_data/revenue_b1 — группы фирм по темпам роста, интервальные и оконные результаты;
- outputs/real_data/revenue_b2 — отраслевой подкорпус выручки, карты читаемости и шоковые сводки.

Эти приложения сохраняют полную воспроизводимость исследования, но не перегружают основной текст деталями, которые лишь усиливают уже доказанные тезисы.